深度时间序列模型：综合综述与基准测试

王宇轩、吴海旭、董家祥、刘勇、王晨、龙明盛、王建民（P）

（综述论文）

摘要：时间序列是按离散时间顺序排列的数据点，在现实场景中无处不在。因其复杂动态特性，时间序列在学习建模上面临独特挑战，如非线性模式与时变趋势的纠缠。近年来，技术已从传统统计转向深度学习。本文综述了各类分析任务下深度时间序列模型的设计，从基础模块和架构角度梳理现有文献。此外，我们开发发布了TSLib，作为深度时间序列模型的公平基准测试库。TSLib实现了41种主流模型（含小型和大型），涵盖30个跨领域数据集及5种常见分析任务。基于此，我们评估了16种流行深度时间序列模型和6种先进基础模型。实证表明，特定结构模型仅擅长特定任务，为相关研究与应用提供了见解。

索引术语：时间序列分析、深度时序模型、时序基础模型、综述、基准测试。

I. 引言

时间序列是按离散时间顺序索引的数据点序列 ，在实际应用中无处不在，如金融风险评估、能源可持续性和天气预报。随着各领域海量时间序列数据可用性提升，该领域取得巨大进展。与具有客观规定语法或直观图像和文本数据模式各异，时间序列语义主要源于时序变化 [3]。这给理解带来重大挑战，尤其在识别序列依赖、趋势、季节性及复杂动态方面。因此，需采用复杂方法以提取其有意义的时序表示。

时间序列分析因实际应用不可或缺而长期成为关键研究领域 [4], [5], [6]。该领域通过深入探究序列数据中的时变特征以揭示潜在模式，从而促进精准预测与明智决策。其核心在于识别数据内生的复杂时序依赖及变量相关性。捕捉这些纠缠关系可揭示底层动态，支撑预测、分类、插补及异常检测等广泛下游任务。

传统方法如ARIMA [1]、指数平滑和频谱分析 [7]长期作为时间序列分析的可靠工具。这些基于统计的方法有助于揭示模式、趋势和季节性。然而，其对线性和平稳性的严格假设限制了其在动态数据流中的应用，难以捕捉实际数据中的复杂非线性关系和长期依赖。

深度模型在自然语言处理（NLP）[16], [17]、计算机视觉（CV）[18], [19]和推荐系统 [20]等领域表现显著。近年来，深度学习模型 [3], [21]-[24]因能有效捕捉时间序列的复杂依赖关系，成为优于传统统计方法的分析工具。此外，源自NLP的Transformer模型凭借注意力机制，在处理大规模数据方面展现出卓越能力 [17]，并被适配用于学习时间序列。其选择性关注输入序列不同部分的优势，有助于更细致地揭示时间与变量间的依赖关系。

2024年6月26日收稿，2026年2月16日修订，5月1日接受。出版日期2026年5月6日；当前版本2026年9月4日。本研究获中国教育部基础与交叉学科突破计划（JYB2025XDXM803）、国家自然科学基金（U2342217）及国家大数据软件工程技术研究中心支持。S. Rambhatla推荐录用。（Yuxuan Wang、Haixu Wu和Jiaxiang Dong贡献相同。）通讯作者：Mingsheng Long；Jianmin Wang。

作者均隶属清华大学BNRist软件学院（北京100084；邮箱：wangyuxu22@mails.tsinghua.edu.cn；ming-sheng@tsinghua.edu.cn；jimwang@tsinghua.edu.cn）。

代码和数据集见https://github.com/thuml/Time-Series-Library。

DOI: 10.1109/TPAMI.2026.3690845

0162-8828 © 2026 IEEE. All rights reserved, including rights for text and data mining, and training of artificial intelligence and similar technologies. Personal use is permitted, but republication/redistribution requires IEEE permission. See https://www.ieee.org/publications/rights/index.html for more information.

Authorized licensed use limited to: XIDIAN UNIVERSITY. Downloaded on October 13,2026 at 08:55:48 UTC from IEEE Xplore. Restrictions apply.

表I
我们的工作与其他相关综述的差异。我们对任务和模型进行了系统综述，并提供了全面的基准测试

Survey	Analysis Task				Model Architecture					Benchmark
	Forecasting	Classification	Imputation	Anomaly Detection	MLP	CNN	RNN	GNN	Transformer	
Fawaz et al. (2019) [8]		✓			✓	✓	✓			
Braei et al. (2020) [9]				✓	✓	✓	✓			
Torres et al. (2021) [10]	✓					✓	✓	✓		
García et al. (2021) [11]				✓		✓	✓	✓		
Wen et al. (2022) [12]	✓	✓		✓					✓	
Jin et al. (2023) [13]	✓	✓	✓	✓				✓		
Shao et al. (2023) [14]	✓				✓	✓	✓	✓	✓	✓
Qiu et al. (2024) [15]	✓				✓	✓	✓	✓	✓	✓
This Survey	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓

尽管近年来出现了各种针对不同分析任务设计的时间序列模型，但目前缺乏涵盖任务和模型的现有方法的全面概述。如表I所示，以往的综述仅聚焦于特定模型架构或分析任务。例如，文献[8], [9], [10], [11]分别综述了针对特定时间序列分析任务的深度学习方法，但未纳入Transformer等先进架构。若干综述[12], [13]针对时间序列分析提供了最新的综述，聚焦于特定深度学习架构（如图神经网络和Transformer）。最近，BasicTS [14]和TFB [15]推出了预测基准，能够对现有方法进行无偏评估，但未提供这些深度模型架构设计的概述。

在本综述中，我们尝试为研究人员和从业者提供一份关于深度时间序列模型的独特综述，从基础模块到现代架构逐步展开。为推动实际应用，本文提供了一个时间序列基准，用于公平评估并确定现有模型的有效适用范围。本综述的结构如下：第二部分介绍时间序列分析的背景概念；第三部分阐述广泛应用于主流深度时间序列模型的基础模块；第四部分从架构设计角度综述现有深度时间序列模型；第五部分探讨时间序列基础模型的最新进展；第六部分介绍一款易于使用的开源基准——时间序列库（TSLib），同时包含大量实验对比与详细分析；第七部分简要讨论未来的研究方向，第八部分对本综述进行总结。

二、预备知识

A. 时间序列

时间序列是按时间顺序排列的 T 个观测值序列，可表示为 $\mathbf{X} = \{\mathbf{x}_1, \mathbf{x}_2, \ldots, \mathbf{x}_T\} \in \mathbb{R}^{T \times C}$，其中 $\mathbf{x}_t \in \mathbb{R}^C$ 为时间戳 t 处的观测值，C 为变量数量。需注意，时空数据（例如视频或天气记录）也可视为一种特殊的时间序列，其中“变量维度”对应上述概念中的视频空间像素[25]。然而，以往针对时空数据的研究主要依赖高度结构化的空间信息[26]，这限制了其在一般变量上的应用，例如语义含义不同的异构变量。本文聚焦于更通用的形式化定义，即不假设变量维度内部存在任何空间结构。根据该定义，时间序列分析的本质是捕捉并利用观测值之间的时间依赖关系及变量间相关性。

时间依赖：鉴于时间序列数据固有的序列特性，一种明显的技术范式是捕捉一组历史数据的时间依赖关系。本质上，时间依赖指的是不同时间点或子序列之间存在的复杂关联。传统统计方法，例如以ARIMA[1]为代表的自回归原理相关方法，已被广泛用于对这类依赖关系进行建模。由于其简洁性和可解释性，这类统计方法在潜在时间动态复杂度较低的场景中仍具有重要应用价值。

变量相关性：除时间依赖外，理解不同变量间的相关性对于分析多变量时间序列至关重要，尤其是在高维场景下。这些相关性包含了多个测量值随时间变化的复杂交互与关联。阐明这些关系可为理解潜在动态和隐含过程提供重要见解。以VAR[27]为代表的传统方法将自回归概念扩展至多变量，从而能够捕捉跨时间的变量间关系。然而，VAR模型将每个变量表示为所有其他变量滞后值的线性组合，这本质上限制了其捕捉未对齐或非线性关系的能力。

上述时间序列的基本要素为构建实用分析模型带来了诸多挑战。传统统计方法虽能提供基础理论见解，但其固有依赖数据的假设（如线性和平稳性）往往限制了它们在复杂现实场景中的适用性。近年来，

Authorized licensed use limited to: XIDIAN UNIVERSITY. Downloaded on October 13,2026 at 08:55:48 UTC from IEEE Xplore. Restrictions apply.

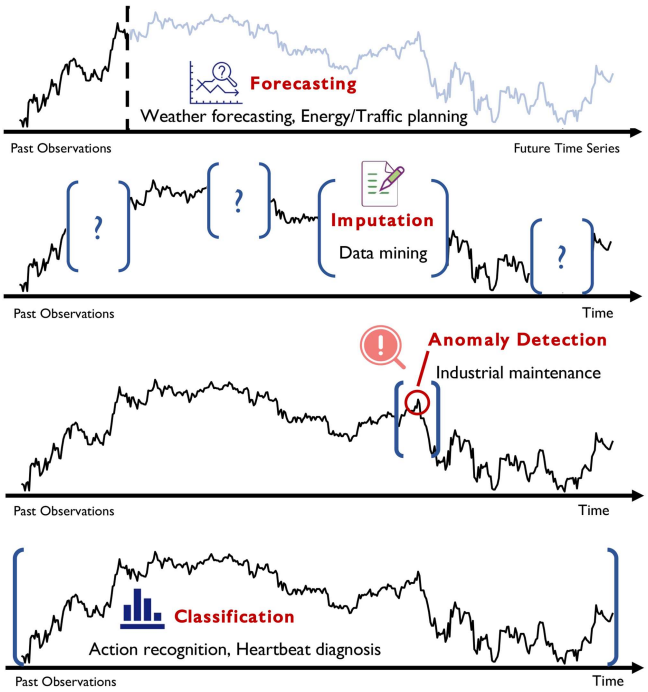


图1. 不同时间序列分析任务的示意图。

深度学习模型已成为时间序列建模的强大替代方案。其表示学习能力和对大数据的可扩展性，使其特别适用于高维非线性时间序列数据，能够有效完成各类分析任务。

B. 时间序列分析任务

时间序列分析基于时间序列数据中的潜在模式与趋势，涵盖各类下游应用，包括预测 [28]、[29]、插补 [30]、[31]、[32]、分类 [8]、[33] 以及异常检测 [5]、[34]，各项应用在不同领域中各有其独特用途，如图1所示。

预测是时间序列分析中的一项基础任务，要求模型挖掘时间依赖关系与动态模式。通过捕捉过去与未来数据之间的关联，预测模型旨在预测输入序列的未来值或趋势。在实际应用中，因传感器故障、数据损坏或测量缺失导致的缺失数据十分常见，这使得对时间序列插补以获取更高质量数据的需求日益增长。与基于历史观测值预测未来值的预测不同，插补侧重于利用可用上下文信息重建缺失值。异常检测涉及识别时间序列中的异常模式，这些模式可能表明需要进一步调查的关键事件、系统故障或异常值。最后，分类会根据给定时间序列的特征为其分配标签或类别，该任务广泛应用于医学诊断等领域。

鉴于时间序列分析的多样性，一系列深度学习模型已应运而生，以应对不同任务中的特定挑战。该调查并未采用以任务为中心的视角来研究详尽的细节，而是采用以模型为中心的视角来研究深度时间序列模型，重点关注其基本模块与架构设计，以解决捕捉大规模时间序列数据集底层时间依赖关系及变量间依赖关系的基础问题。

III. 基础模块

在过去十年中，时间序列建模方法取得了显著发展，已从传统统计模型转向复杂的深度学习模型。尽管取得了这些进展，许多经典工具和分析算法仍被广泛使用，并继续作为现代深度模型的基础设计原则。在本节中，我们将重点介绍经典时间序列分析的主要工具，并展示它们如何被整合为当代深度时间序列模型的基本组成部分。

A. 平稳化

平稳性是时间序列分析中的基础概念，指时间序列的统计特性随时间保持恒定的性质。平稳时间序列具有恒定的均值和方差，这简化了统计分析，更易于捕捉时间序列的潜在模式与行为。由于许多基于统计的时间序列分析方法从根本上以平稳性为前提，将非平稳数据转换为平稳形式已成为必要的预处理步骤。传统上，这种平稳化通过差分或对数变换等方法实现。在近期的深度学习方法中，数据归一化 [35] 以简单而有效的方式承担了平稳化的作用，它在标准化观测值分布的同时保留了内在变异，进一步有助于缓解源域与目标域之间的分布偏移。

近期的深度学习架构已开发出专门的层来解决非平稳问题。深度自适应输入归一化（DAIN）层[36]被提出，用于根据时间序列数据的原始分布对其进行自适应标准化。RevIN [37]引入了一种带有可学习仿射变换的可逆实例归一化技术，使模型能够绕过非平稳输入。此外，非平稳Transformer [38]（下文简称为Stationary）提出了一种更简单但更有效的序列平稳化技术，无需额外参数即可提升非平稳序列的预测能力。具体来说，对于具有 T 个时间戳和 C 个变量 $\mathbf{X} = \{\mathbf{x}_1, \mathbf{x}_2, \ldots, \mathbf{x}_T\} \in \mathbb{R}^{T\times C}$ 的序列，其中 $\mathbf{x}_t \in \mathbb{R}^C$，Stationary [38]的概述可总结如下：

$$\mu_{\mathbf{x}} = \frac{1}{T}\sum_{i=1}^{T}\mathbf{x}_i,\ \sigma_{\mathbf{x}}^2 = \frac{1}{T}\sum_{i=1}^{T}(\mathbf{x}_i - \mu_{\mathbf{x}})^2,$$
$$\bar{\mathbf{X}} = \frac{\mathbf{X} - \mu_{\mathbf{x}}}{\sqrt{\sigma_{\mathbf{x}}^2 + \epsilon}},\ \bar{\mathbf{Y}} = \mathrm{Model}(\bar{\mathbf{X}}),\ \hat{\mathbf{Y}} = \sigma_{\mathbf{x}}\bar{\mathbf{Y}} + \mu_{\mathbf{x}}, \quad (1)$$

其中 ϵ 是为保证数值稳定性而设定的较小值。$\mu_{\mathbf{x}}, \sigma_{\mathbf{x}}^2 \in \mathbb{R}^{1\times C}$ 是变量特有的均值和方差。为恢复

Authorized licensed use limited to: XIDIAN UNIVERSITY. Downloaded on October 13,2026 at 08:55:48 UTC from IEEE Xplore. Restrictions apply.

原始序列的分布与非平稳性，还通过反归一化模块利用输入的均值和方差统计量增强模型输出 $\overline{\mathbf{Y}}$。

平稳化的理念及上述技术已在后续的深度时间序列模型中得到广泛应用[23]、[39]、[40]。例如，SAN [41]等近期研究通过对互不重叠、大小相同的片段进行归一化而非对整个序列归一化，并引入统计预测模块来预测未来片段的分布，重新思考了非平稳数据的本质。

B. 分解

分解[42]、[43]作为时间序列分析中的一种常规方法，将时间序列拆分为多个更具规律模式的分量，采用分而治之的范式来探究复杂的序列变化。在过往研究中，人们探索了一系列典型的分解方案。

1) 季节-趋势分解：季节-趋势分解[44]、[45]是提升原始时间序列数据可预测性的最常用方法之一。该技术将序列拆分为不同的加性分量：趋势、季节、周期和不规则分量。趋势分量代表数据随时间变化的整体长期模式；周期分量反映数据内部重复但非周期性的波动；季节分量表示固定周期内的重复模式；不规则分量则是其他分量被移除后时间序列的残差或剩余部分。

这种分解可通过滤波器或指数平滑[46]、[47]等数学工具实现。过往的统计方法主要采用趋势-季节分解作为数据预处理步骤[48]。在深度学习模型中，Autoformer[22]首次将分解的思路引入深度学习架构，并提出了一种基于平均池化的序列分解模块作为基础模块，用于提取输入序列或深度特征中的季节部分和趋势-周期部分：

$$\begin{aligned}\mathbf{X}_{\mathcal{T}} &= \mathrm{AvgPool}\left(\mathrm{Padding}(\mathbf{X})\right),\\ \mathbf{X}_{\mathcal{S}} &= \mathbf{X} - \mathbf{X}_{\mathcal{T}}.\end{aligned} \tag{2}$$

所提出的分解模块基于时间平均池化层实现，可有效捕获趋势 $\mathbf{X}_{\mathcal{T}}$，剩余部分则作为季节部分 $\mathbf{X}_{\mathcal{S}}$。该设计已被后续研究[6]、[49]、[50]、[51]、[52]广泛采用，作为原生构建模块，用于解耦深度特征中的潜在模式。

2) 基展开：基展开是一种数学方法，用于用一组新的预定义函数来表示某个函数或一组数据点。这些新函数构成了函数空间的基，使得该空间中的任意函数都能表示为这些基函数的线性组合。在时间序列分析中，基展开通过将时间序列分解为基本变化的组合来揭示非线性时间关系，从而提升可解释性。作为代表性方法，N-BEATS[24]通过利用以下方式对时间序列进行分层分解

全连接层生成用于向后预测和向前预测的展开系数。在所提出的分层架构的第 l 个模块中，该操作为

$$\begin{aligned}\mathbf{X}_l &= \mathbf{X}_{l-1} - \hat{\mathbf{X}}_{l-1}\\ \hat{\mathbf{X}}_l, \hat{\mathbf{Y}}_l &= \mathrm{Block}_l(\mathbf{X}_l),\end{aligned} \tag{3}$$

其中 $\widehat{\mathbf{X}}_{l-1}$ 为反向预测结果，用于限制模块近似输入信号 $\mathbf{X}_{l-1}$；随后 $\mathbf{X}_l$ 从 $\widehat{\mathbf{X}}_{l-1}$ 中移除已估计的信号 $\widehat{\mathbf{X}}_{l-1}$ 部分，实现分层分解。$\widehat{\mathbf{Y}}_l$ 基于分解后的输入 $\mathbf{X}_l$ 生成部分预测结果，最终结果 $\widehat{\mathbf{Y}} = \sum_l \widehat{\mathbf{Y}}_l$ 为各部分之和。

随后，N-HiTs[53]通过在全连接模块前加入子采样层对N-BEATS进行了重新定义。该改进通过多频率数据采样增强了输入分解效果，并通过多尺度插值提升了未来预测性能。DEPTS[54]通过引入周期状态作为隐变量，为周期性时间序列提出了一种新颖的解耦公式。随后，该模型在残差学习的基础上开发了深度展开模块，用于在观测信号与这些隐式周期状态之间执行逐层展开。类似地，DEWP[55]是一种按堆叠方式展开的模型，旨在处理多变量时间序列数据。模型中的每个堆叠层包含一个用于捕获多变量之间依赖关系的变量展开模块，以及一个用于学习时间依赖关系的时间展开模块。

3) 矩阵分解：前述两种分解方法主要针对单变量序列，或以变量独立的方式应用于多变量序列。在此，我们探究尤其适用于多变量时间序列的基于分解的因子分解。这些高维数据可形式化为矩阵，其中行代表变量，列代表时间点。由于多变量时间序列中的变量往往高度相关，可将其降维至更紧凑的空间。矩阵分解方法 [56] 通过将高维序列数据分解为低维潜在空间中两个矩阵的乘积来实现这一点。对于多变量时间序列 $\mathbf{X} \in \mathbb{R}^{T\times C}$，该矩阵可通过两个低秩嵌入矩阵 $\mathbf{X} \approx \mathbf{F}\widehat{\mathbf{X}}$ 的乘积来近似，其中 $\mathbf{F} \in \mathbb{R}^{T\times k}, \widehat{\mathbf{X}} \in \mathbb{R}^{k\times C}$ 和 k 为超参数。

除了估计之外，正则化项在基于因子分解的模型中对于缓解过拟合至关重要。超越了将平方Frobenius范数作为正则化项的经典设计，时间正则化矩阵分解（TRMF）[57] 设计了一种基于自回归的时间正则化项，用于描述潜在时间嵌入之间的时间依赖关系。此外，文献 [58] 通过新的空间自回归正则化项扩展了TRMF，以同时学习空间和时间自相关性，从而估计低秩潜在因子。为了更好地对现实世界时间序列数据的趋势和季节性进行建模，NoTMF [59] 将向量自回归过程与差分运算集成到经典的低秩矩阵分解框架中。为解决参数调优的挑战，BTF [60] 提供了一种完全贝叶斯方法，将概率

Authorized licensed use limited to: XIDIAN UNIVERSITY. Downloaded on October 13,2026 at 08:55:48 UTC from IEEE Xplore. Restrictions apply.

矩阵分解和向量自回归过程统一在单个概率图模型中。与基于自回归的时间正则化不同，DeepGLO [61] 利用时间卷积网络来捕捉非线性依赖关系。同样，LSTM-GL-ReMF [62] 采用基于LSTM的时间正则化项来处理复杂的长期和短期非线性时间相关性，并辅以图拉普拉斯空间正则化项 [63] 来捕捉空间相关性。

C. 傅里叶分析

傅里叶分析 [64]、[65] 是一种强大的数学技术，可将物理信号转换至频域，从而凸显原始数据的固有周期性。长期以来，它一直被视为各领域的基础分析工具。由于时间序列数据通常记录为从连续信号中采样得到的离散观测值序列，傅里叶分析自然成为时间序列建模的主流方法，兼具出色的有效性与效率 [66]、[67]。引入傅里叶域不仅能提升原始序列的表示效果，还能提供关于时间动态的全局视角。生成的频谱分布为时间序列的基本周期成分和潜在循环行为提供了关键洞察。在实际应用中，快速傅里叶变换（FFT）[68] 和小波变换（WT）[69] 等算法充当了连接离散时域与频域的基础桥梁。这些技术在深度时间序列模型的模块化设计中越来越受欢迎 [70]、[71]、[72]、[73]、[74]、[75]、[76]、[77]。现有方法大致可分为两类：时域建模与频域建模。

1) 时域建模：傅里叶变换的基本原理是，序列数据可通过一系列周期信号进行分解和表示。因此，可通过分析振幅最高的成分，识别数据中潜在的主导周期及其对应频率。作为一项重要的集成技术，TimesNet [3] 采用快速傅里叶变换（FFT）提取振幅值最高的显著频率，再基于这些已识别的周期将一维时间序列数据重塑为二维空间，从而促进分层表示学习。PDF [78] 以 TimesNet 为基础，认为数值较大的频率能更清晰地区分长期与短期关系。

频域表示提供了关于振幅和相位的宝贵信息。例如，低频成分对应信号中较慢的变化或潜在趋势，而高频成分则捕捉更精细的细节或快速波动。大量研究致力于利用频域信息提升模型捕捉时间依赖关系的能力。FiLM [79] 将傅里叶分析与低秩近似相结合，并引入了频率增强层（FEL）。该方法保留了部分与低频傅里叶成分及顶部特征空间相关的表示，从而有效降低噪声并加快训练速度。FITS [80] 集成了低通滤波器（LPF），用于消除高于指定截止频率的高频成分，在保留必要信息的同时压缩了模型规模。与之观点相反，FEDformer [81] 认为仅保留低频成分不足以进行时间序列建模，因为这可能会忽略重要的数据波动。基于这一考虑，FEDformer 旨在通过使用随机选定的固定数量傅里叶成分来表示序列，涵盖高频和低频的贡献，从而捕捉时间序列的全局视角。

除了单纯利用傅里叶变换得到的序列信息外，一些研究还聚焦于通过快速傅里叶变换实现高效计算。自相关是时间序列分析中的一个基本概念，用于衡量数据序列中不同时间点观测值之间的依赖关系。维纳-辛钦定理 [82] 提供了平稳随机过程的自相关函数与功率谱密度（PSD）之间的数学关系，其中自相关函数是 PSD 的逆傅里叶变换。将数据视为实离散时间过程，Autoformer [22] 提出了一种自相关机制，结合高效的快速傅里叶变换来捕捉序列级相关性。

2) 频域建模：基于信号处理领域时频分析的进展，已开发出多种方法，可同时在时域和频域分析时间序列。例如，ATFN [83] 利用增强型序列到序列模型学习非平稳时间序列的趋势特征，同时通过频域模块捕捉周期性模式。TFAD [84] 引入了一种基于时频分析的模型，采用时间卷积网络来获取时域和频域表示。

部分研究开发了专门的深度学习架构，用于处理时间序列的频域。STFNet [71] 将短时傅里叶变换应用于输入信号，并直接在频域中执行滤波、卷积和池化操作。StemGNN [85] 结合图傅里叶变换（GFT）和离散傅里叶变换，以同时建模序列间相关性和时间依赖性。EV-FGN [86] 在嵌入的时空平面上使用二维离散傅里叶变换，并执行图卷积，以在频域中同时捕获时空依赖性。FreTS [87] 利用离散傅里叶变换（DFT）将数据转换为频域频谱，并引入专为复数设计的频域多层感知机（MLP），对实部和虚部分别进行建模。FCVAE [88] 将全局和局部频域特征同时整合到条件变分自编码器（CVAE）的条件中。最新的TSLANet [89] 提出了一种轻量型自适应频谱块（ASB），以取代自注意力机制，该机制通过基于傅里叶的全局和局部滤波器乘法实现。FourierDiffusion [90] 将基于分数的SDE扩散模型的公式扩展到复值数据，因此在频域中实现了时间序列扩散。

Authorized licensed use limited to: XIDIAN UNIVERSITY. Downloaded on October 13,2026 at 08:55:48 UTC from IEEE Xplore. Restrictions apply.

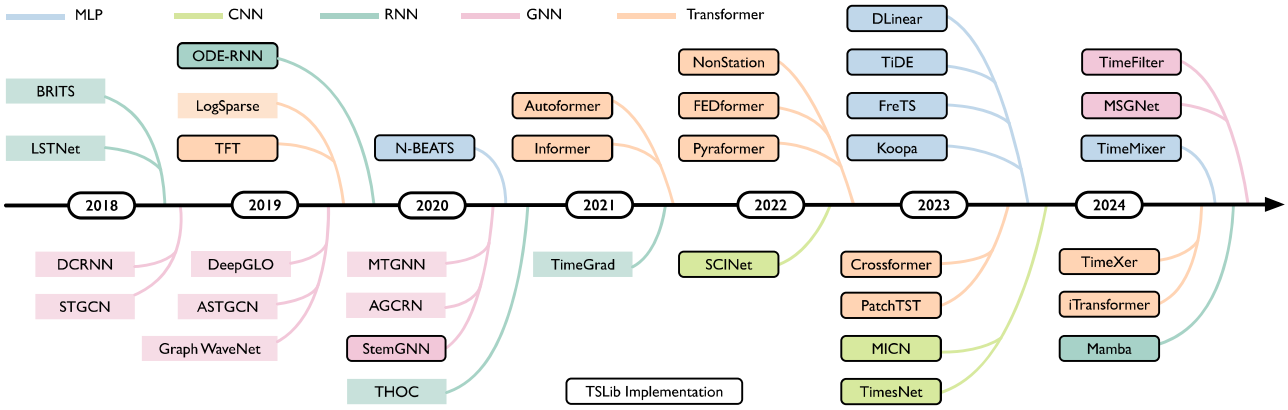


图2. 按时间顺序排列的代表性时间序列模型概述。我们根据模型的架构用不同颜色标记它们。

将扩散模型的公式扩展到复值数据，因此在频域中实现了时间序列扩散。

IV. 模型架构

如第 II 节所述，时间序列模型旨在挖掘内在的时间依赖关系与变量相关性，以揭示观测数据中潜藏的模式与动态变化。根据架构主干（图 2），现有方法可大致分为五类，即基于 MLP、基于 RNN、基于 CNN、基于 GNN 以及基于 Transformer 的方法。这些架构各有独特的优势与设计原则，用于应对时间序列分析中的特定挑战。在本节中，我们将对当前的深度时间序列模型进行全面的技术综述，重点介绍它们在时间序列建模方面的不同方法。

A. 多层感知机

作为传统统计时间序列模型的基石，自回归（AR）模型假定模型输出线性依赖于其自身的历史值。受自回归模型显著效能的启发，多层感知机（MLP）已成为时间序列建模的热门架构。

作为基于MLP的模型的典型代表，N-BEATS [24] 未包含任何特定于时间序列的组件来捕捉时间模式。具体而言，如（3）中所述，N-BEATS由深度堆叠的全连接层构成，每层包含两个残差分支，一个用于反向预测，另一个用于预测分支。基于神经基函数扩展的思想，N-HiTs [53] 通过多速率信号采样和分层插值提升预测效果，而N-BEATSx [91] 则通过引入外生变量进一步扩展了该框架。

近期研究，尤其是DLinear [49]，对复杂深度架构在时间建模中的有效性提出了质疑。该研究认为，在原始空间中采用简单线性回归即可在建模效果和效率上均取得显著表现。如图3所示，许多流行的基于MLP的深度时间序列模型，主要为预测任务设计，都依赖于这类简单线性层。FITS [80] 同样轻量且有效，它主张时间序列预测可被视为

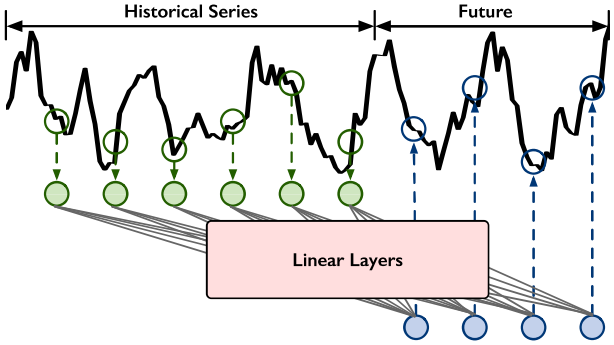


图3. 基于MLP的基础模型在预测任务中的示意图，该模型通过可学习的MLP参数捕捉未来与过去的依赖关系。

复频域内的插值任务。它引入了复值线性层，直接在频域中学习幅度缩放和相位偏移。受计算机视觉领域MLP-Mixer [92] 的启发，多项研究尝试利用MLP来同时建模时间和变量依赖关系。TSMixer [93] 包含交替的时间混合和特征混合MLP，以从不同角度提取信息。为更好地捕捉全局依赖关系，FreTS [87] 研究了频域MLP的学习模式，这些模式在序列间和序列内尺度上运行，以捕捉多变量数据中的通道级和时间级依赖关系。

除了在离散时间点上的简单线性层之外，TimeMixer提出时间序列在不同采样尺度上呈现出不同的模式，并引入了基于MLP的多尺度混合架构。TiDE [94] 结合外生变量以增强时间序列预测。Koopman理论和动态模式分解（DMD）[95] 是分析复杂动力系统的主流方法，Koopa [96] 基于该理论和方法，通过端到端的预测训练框架分层解耦动力学，并且可利用实时传入的序列进行在线开发。

B. 循环神经网络

循环神经网络（RNNs）专为序列数据设计[97]、[98]、[99]，如自然语言

Authorized licensed use limited to: XIDIAN UNIVERSITY. Downloaded on October 13,2026 at 08:55:48 UTC from IEEE Xplore. Restrictions apply.

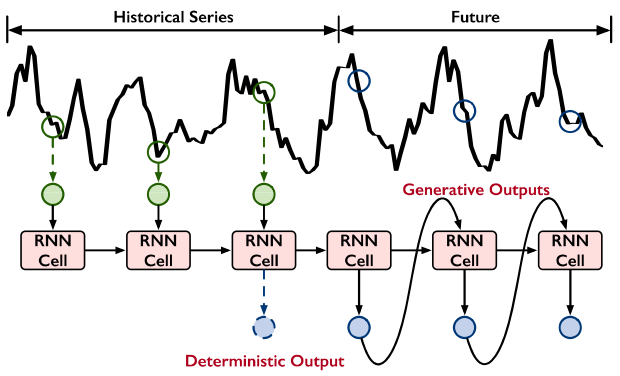


图 4. 预测任务中基于 RNN 的模型示意图。

处理[100]和音频建模[101]。鉴于时间序列固有的序列特性，RNN 自然成为时间序列分析的热门选择[102]，如图 4 所示。现有的基于 RNN 的深度时间序列模型主要致力于解决普通循环结构导致的梯度消失问题，以及对多元变量间的相互关联进行建模。

众多前期研究[103]、[104]、[105]、[106]、[107]利用了多种 RNN 变体来捕捉复杂的依赖关系。LSTNet [108]将循环结构与卷积层相结合，以捕捉变量间的短期局部依赖关系和时间序列的长期模式。它还引入了一种基于周期模式的新型循环跳跃组件，以缓解长期依赖关系建模中的梯度消失问题。类似地，DA-RNN [109]将循环单元与双阶段注意力机制相结合，以便在每个时间步自适应地提取相关序列。除确定性预测外，DeepAR [110]提出了一种自回归循环网络，用于预测后续时间点的概率分布。从技术层面而言，它不仅能学习时间序列的季节性特征，还能学习对给定协变量的依赖关系，使模型即使在历史数据极少或没有的情况下也能进行预测。近期研究[75]引入了一种新型 DTWAtt 模块，该模块将依赖于数据的小波函数集成到 BiLSTM 网络中，作为小波注意力，用于分析非平稳时间序列中的动态频率成分。

基于马尔可夫状态表示，状态空间模型（SSM）[111]是用于捕捉随机动力学系统中观测测量值之间概率依赖关系的经典数学框架。尽管 SSM 在处理结构良好的时间序列数据时已被证明具有有效性和高效性，但传统方法必须单独拟合每个序列，因此无法从相似时间序列的数据集中推断出共享模式。随着深度学习的出现，现代 SSM 通常以循环方式实现。通过适配和传播确定性隐藏状态，RNN 为经典状态空间模型提供了另一种选择，可表示连续数据中的长期依赖关系。因此，一些研究[112]、[113]试图将经典状态空间模型与深度神经网络相融合。其中具有代表性的是深度状态空间模型（DSSM）[114]，它利用循环神经网络（RNN）对特定线性 SSM 进行参数化，从而在学习复杂模式的同时融入结构假设。结构化状态空间序列模型（S4）[115]引入了一种新型的 SSM 参数化方法，通过对矩阵 $\mathbf{A}$ 进行低秩校正，实现了稳定的对角化，显著提升了模型的长期建模能力。最近，Mamba [116]成为一种强大的方法，用于对序列长度具有线性复杂度的长序列数据进行建模。Mamba 利用一种简单的选择机制，根据输入对 SSM 参数进行参数化，能够识别观测值中的有效信息，为时间序列分析提供了一种有效的方法。

除了在离散时间步之间进行学习之外，神经常微分方程（Neural ODEs）[117]将 RNN 扩展为连续时间版本。从技术上讲，神经 ODE 通过神经网络对隐藏状态的导数进行参数化，从而以可微分的方式无缝建模时间演化。鉴于其对连续时间进行建模的能力，多项研究探索了将神经 ODE 应用于处理不规则采样的时间序列数据[118]、[119]。在这些进展的基础上，[120]将神经 ODE 与物理先验相结合，用深度网络增强物理模型，以预测复杂动力学。这些能力使神经 ODE 成为基于 RNN 方法的有力补充，为时间序列分析提供了更灵活、更稳健的方法。

C. 卷积神经网络

由于时间序列的语义信息主要隐藏在时间变化中，卷积神经网络（CNN）[18]、[121]已成为极具竞争力的骨干模型。其优势在于能够捕捉局部特征并识别复杂模式，这一点在各类计算机视觉任务中已得到显著成效的验证，包括图像分类[122]、分割[123]和目标检测[124]。

考虑到时间序列数据的时间连续性，现有研究[125]、[126]采用一维卷积神经网络（1D CNN）来识别时间序列数据的局部模式。近期的SCINet[127]采用具有分层下采样-卷积-交互架构的标准卷积，以捕捉不同时间分辨率下的动态时间依赖关系。受掩码卷积[25]思想的启发，Wavenet[128]引入因果卷积和膨胀因果卷积，用于建模长程时间因果关系。类似地，时间卷积网络（TCN）[129]通过堆叠膨胀系数逐渐增大的膨胀卷积核，以获得较大的感受野。然而，TCN有限的感受野往往会阻碍其捕捉时间序列数据中全局关系的能力。基于TCN，MICN[130]是一种局部-全局卷积网络，它结合不同的卷积核，从局部和全局角度对时间相关性进行建模。ModernTCN[131]通过分别采用深度可分离卷积（DWConv）和卷积前馈网络（ConvFFN），增强了传统TCN的性能，以分别捕捉跨时间和跨变量的依赖关系。

Authorized licensed use limited to: XIDIAN UNIVERSITY. Downloaded on October 13,2026 at 08:55:48 UTC from IEEE Xplore. Restrictions apply.

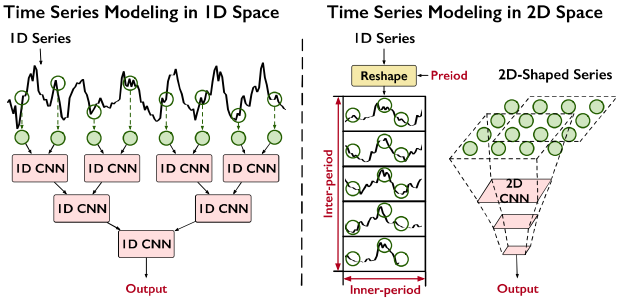


图5. 从表示空间角度对比现有基于CNN的时间序列模型。

受时间序列周期性启发，TimesNet[3]突破了一维建模局限。如图5所示，它基于估计周期长度，在TimesBlock中将一维序列 $\mathbf{X}_{1\mathrm{D}}$ 转换为 2D 张量集 $\mathbf{X}_{2\mathrm{D}} = \left\{\mathbf{X}_{2\mathrm{D}}^{1}, \ldots, \mathbf{X}_{2\mathrm{D}}^{k}\right\}$，其中列体现周期间变化，行体现周期内变化。此处 k 为对应多周期的超参数。随后，TimesNet应用Inception模块[132],[133]处理这些二维张量，概括为：

$$\begin{aligned}
\mathbf{X}_{2\mathrm{D}}^{i} &= \operatorname{Reshape}\left(\operatorname{Padding}\left(\mathbf{X}_{1\mathrm{D}}\right)\right), \ i \in \{1, \ldots, k\} \\
\hat{\mathbf{X}}_{2\mathrm{D}}^{i} &= \operatorname{Inception}\left(\mathbf{X}_{2\mathrm{D}}^{i}\right), \ i \in \{1, \ldots, k\} \\
\hat{\mathbf{X}}_{1\mathrm{D}}^{i} &= \operatorname{Trunc}\left(\operatorname{Reshape}\left(\hat{\mathbf{X}}_{2\mathrm{D}}^{i}\right)\right), \ i \in \{1, \ldots, k\},
\end{aligned} \tag{4}$$

其中 $\mathbf{X}_{2\mathrm{D}}^{i}$ 为第 i 个变换后的 2D 张量。经Inception模块 $(\cdot)$ 处理后， 2D 表示被还原为 1D 以进行聚合。这些变换使TimesNet能同时有效捕捉多尺度的周期内与周期间变化。此外，借助分层卷积层，TimesNet可学习高低级表示，支持四项不同任务中的全面时间序列分析。

D. 图神经网络

多变量时间序列因变量间复杂非线性相关而分析困难。为此，图神经网络（GNN）[134]、[135]被广泛应用。如图6所示，GNN将数据建模为时空图（节点代表变量），提取邻接关系并捕捉属性时序演变，为理解潜在动态提供框架。

GNN架构旨在建模多变量数据中的潜在拓扑关系。现有研究大致分为两类：依赖预定义图结构作为输入，或动态学习图结构。

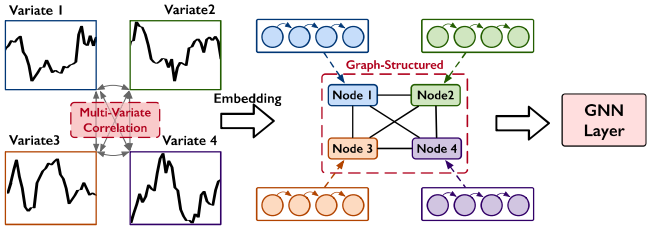


图6 采用GNN对多变量时间序列进行建模的示意图

DCRNN [136]利用扩散卷积建模交通空间依赖性，并结合循环神经网络捕捉时间动态。STGCN [137]结合图卷积与时间卷积，以捕获传感器间的空间依赖及时间序列中的时间特征。Graph WaveNet [138]融合图卷积与膨胀因果卷积，通过节点嵌入学习自适应依赖矩阵以自动挖掘隐藏空间结构。AGCRN [139]增强传统图卷积，借助节点自适应参数和数据自适应图生成模块，无需预定义图结构即可捕捉时空相关性。MTGNN [140]引入图学习层自适应优化邻接矩阵，以揭示多变量时间序列中的潜在关系。STFGNN [141]采用时空融合图神经网络，结合生成时间图学习局部异质性与全局同质性。StemGNN [85]利用图傅里叶变换（GFT）和离散傅里叶变换（DFT）优势，在频域中对多变量时间序列进行建模。

E. Transformer

鉴于 Transformer 在 NLP [16]、[142]-[145] 和 CV [19]、[146]-[148] 领域的成功，它已成为时间序列分析的强大骨干。凭借自注意力机制 [149]，其擅长捕捉长期依赖与多元相关性。如图 7 所示，现有模型可按注意力表示粒度分为逐点、逐块和逐序列方法。

1) 逐点依赖：鉴于时间序列的序列特性，多数基于 Transformer 的研究采用逐点表示学习，并运用注意力机制捕捉不同时间点间的相关性。在此类逐点建模方法中，数据嵌入作为关键组件，将原始时间序列值映射为

Authorized licensed use limited to: XIDIAN UNIVERSITY. Downloaded on October 13,2026 at 08:55:48 UTC from IEEE Xplore. Restrictions apply.

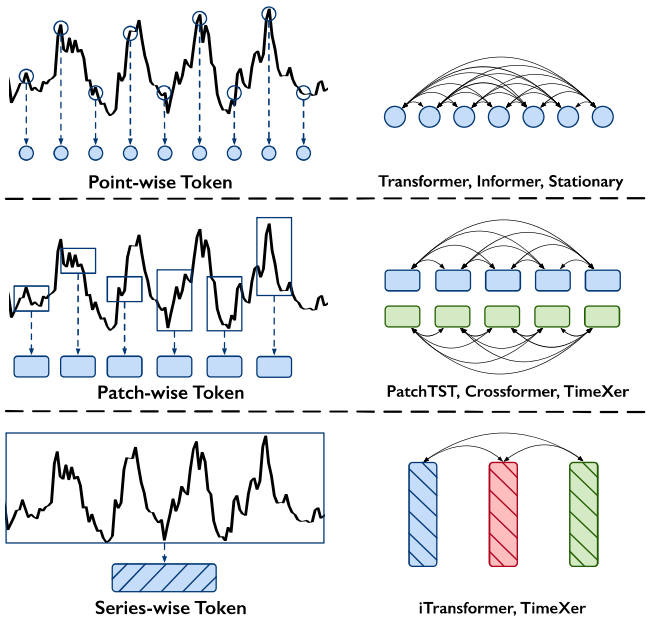


图 7. 基于 Transformer 的时间序列模型所用不同类型分词方式及对应代表性研究的对比，涵盖从逐点、逐块到逐序列的范围。

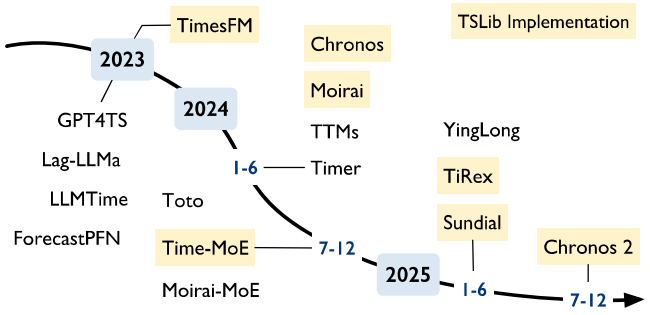


图 8. 时间序列基础模型的最新进展。时间线根据模型的论文或技术报告发布时间绘制。

高维表示。给定时间序列 $\mathbf{X} \in \mathbb{R}^{T \times C}$ 及对应的时间戳信息 $\mathbf{X}^{\mathrm{ts}} \in \mathbb{R}^{T \times D}$，其中 C 为变量数量，D 为时间戳类型，嵌入模块可概括为：

$$\mathbf{H}_t = \mathrm{Projection}(\mathbf{X}_t) + \mathrm{PE}(\mathbf{X}_t) + \mathrm{TE}(\mathbf{X}_t^{\mathrm{ts}})), \quad (5)$$

其中 $\mathbf{H}_t \in \mathbb{R}^{T \times d_{\mathrm{model}}}$ 和 d_{model} 是嵌入表示的维度，值投影 Projection：$\mathbb{R}^C \mapsto \mathbb{R}^{d_{\mathrm{model}}}$ 和时间戳嵌入 TE：$\mathbb{R}^D \mapsto \mathbb{R}^{d_{\mathrm{model}}}$ 通过通道维度线性层实现，$\mathrm{PE}(\cdot)$ 表示绝对位置嵌入，用于保留输入序列的顺序上下文。

为优化 Transformer 架构在时间序列领域的应用，现有研究主要分为两类：设计预处理模块和修改注意力机制。如第 III-A 节所述，RevIN [37] 和 Stationary [38] 等通过在 Transformer 块前后集成归一化与反归一化模块取得优异性能。其中，Stationary [38] 引入反平稳注意力以缓解过度平稳化问题。

由于标准注意力机制的计算复杂度为二次方，因此提出了各种高效注意力机制 [21]、[22]、[81]、[151] 来降低逐点建模带来的复杂度，如表 II 所示。LogSparse [150] 提出卷积自注意力，通过在自注意力层中使用因果卷积生成查询和键来替代标准注意力。Informer [21] 引入了查询稀疏度测量，数值越大表示在自注意力中包含主导信息的概率越高。在此基础上，它设计了 ProbSparse 自注意力，仅选择性使用测量结果最高的前几个查询，从而显著降低了时间和内存的二次复杂度。Pyraformer [151] 构建了多分辨率树并开发了金字塔注意力机制，其中每个节点只能关注其相邻、邻近和子节点。通过计算注意力掩码，Pyraformer 以线性计算复杂度同时捕捉短期和长期时间依赖关系。

2) 逐块依赖：基于块的架构在自然语言处理（NLP）[16] 和计算机视觉（CV）[19] 的 Transformer 模型中发挥着关键作用。由于逐点表示往往难以捕捉时间数据中的局部语义信息，因此多项研究 [23]、[153]、[154] 致力于探索时间序列数据中的块级时间依赖关系。

开创性研究 Autoformer [22] 提出了自相关机制，以替代标准的逐点自注意力，使模型能够学习逐序列依赖关系。基于随机过程理论 [155]，自相关利用快速傅里叶变换发现不同子序列之间的时延相似度。进一步提出了时延模块，用于聚合来自基础周期的相似子序列，而非分散点之间的关系，这是首次在基于 Transformer 的模型中探索子序列级建模。

与修改注意力机制不同，近期多数研究采用数据的分块表示，并通过标准自注意力机制来捕捉分块间的依赖关系 [23], [51], [156]。PatchTST [23] 及其后续研究将时间序列 $\mathbf{X}$ 划分为一系列重叠分块，并按以下方式对每个分块进行嵌入：

$$\{\mathbf{P}_1, \mathbf{P}_2, \ldots, \mathbf{P}_N\} = \mathrm{Patchify}\,(\mathbf{X}),$$
$$\mathbf{H}_i = \mathrm{PatchEmbed}(\mathbf{P}_i) + \mathbf{E}_{\mathrm{pos}}^i. \quad (6)$$

设 P 为分块长度，N 为对应的分块数量，$\mathbf{P}_i$ 是长度为 P 的第 i 个分块。这些分块通过时间线性投影 PatchEmbed：$\mathbb{R}^P \mapsto \mathbb{R}^{d_{\mathrm{model}}}$ 和可学习位置嵌入 $\mathbf{E}_{\mathrm{pos}} \in \mathbb{R}^{d_{\mathrm{model}} \times N}$ 映射到潜在空间。基于标准注意力机制，PatchTST [23] 学习分块间的依赖关系。

Authorized licensed use limited to: XIDIAN UNIVERSITY. Downloaded on October 13,2026 at 08:55:48 UTC from IEEE Xplore. Restrictions apply.

表 II
基于 Transformer 的深度时间序列模型模型卡片（含架构细节）

Category	Method	Architecture	Embeddding	Attention Mechanism
Vanilla	Transformer	Enc-Dec	Standard	$\text{FullAttention}(\mathbf{Q},\mathbf{K},\mathbf{V})=\text{Softmax}(\frac{\mathbf{Q}\mathbf{K}^\intercal}{\sqrt{d}})\mathbf{V}$
Point-wise	LogSparse [150]	Dec-only	Standard	$\widehat{\mathbf{Q}},\widehat{\mathbf{K}}=\text{CausalCov}(\mathbf{H})$ $\text{FullAttention}(\widehat{\mathbf{Q}},\widehat{\mathbf{K}},\mathbf{V})=\text{Softmax}(\frac{\widehat{\mathbf{Q}}\widehat{\mathbf{K}}^\intercal}{\sqrt{d}})\mathbf{V}$
	Informer [21]	Enc-Dec	Standard	$\overline{\mathbf{Q}}=\text{Top}_u\left(\overline{M}(\mathbf{q}_i,\mathbf{K})\right)$ $\text{ProbSparse-Attention}(\mathbf{Q},\mathbf{K},\mathbf{V})=\text{Softmax}(\frac{\overline{\mathbf{Q}}\mathbf{K}^\intercal}{\sqrt{d}})\mathbf{V}$
	Pyraformer [151]	Enc-Dec	Standard	$\text{Pyramid-Attention}(\mathbf{Q},\mathbf{K},\mathbf{V})=\text{Masked}(\text{Softmax}(\frac{\mathbf{Q}\mathbf{K}^\intercal}{\sqrt{d}})\mathbf{V})$
Patch-wise	Autoformer [22]	Enc-Dec	Standard	$\text{Auto-Correlation}(\mathbf{Q},\mathbf{K},\mathbf{V})=\sum_{i=1}^{k}\text{Roll}(\mathbf{V},\tau_i)\widehat{\mathcal{R}}_{\mathbf{Q},\mathbf{K}}(\tau_i)$
	Crossformer [152]	Enc-Dec	Patch-Wise	$\text{FullAttention}(\mathbf{Q},\mathbf{K},\mathbf{V})=\text{Softmax}(\frac{\mathbf{Q}\mathbf{K}^\intercal}{\sqrt{d}})\mathbf{V}$
	PatchTST [23]	Enc-only	Patch-Wise	$\text{FullAttention}(\mathbf{Q},\mathbf{K},\mathbf{V})=\text{Softmax}(\frac{\mathbf{Q}\mathbf{K}^\intercal}{\sqrt{d}})\mathbf{V}$
Variate-wise	iTransformer [39]	Enc-only	Variate-Wise	$\text{FullAttention}(\mathbf{Q},\mathbf{K},\mathbf{V})=\text{Softmax}(\frac{\mathbf{Q}\mathbf{K}^\intercal}{\sqrt{d}})\mathbf{V}$

除 PatchTST 外，Pathformer [157] 提出多尺度 Transformer，通过自适应路径动态选择分块大小以学习多尺度时间表示。

PatchTST 的成功得益于其通道独立设计，即每个时间分块 token 仅封装单序列信息。除捕捉序列内分块级依赖外，近期研究 [51], [156] 还致力于捕获变量间随时间变化的相互依赖。Crossformer [152] 提出包含跨时间和跨维度阶段的两阶段注意力层，以有效捕捉分块 token 间的跨时间及跨变量依赖。对于嵌入向量 $\mathbf{H}\in\mathbb{R}^{N\times C\times d_{\text{model}}}$ ，整体注意力阶段描述如下：

$$\begin{aligned}\mathbf{Z}^{\text{time}}&=\text{Attention}^{\text{time}}\left(\mathbf{H},\mathbf{H},\mathbf{H}\right)\\\mathbf{B}&=\text{Attention}_1^{\text{dim}}\left(\mathbf{R},\mathbf{Z}^{\text{time}},\mathbf{Z}^{\text{time}}\right)\\\overline{\mathbf{Z}}^{\text{dim}}&=\text{Attention}_2^{\text{dim}}\left(\mathbf{Z}^{\text{time}},\mathbf{B},\mathbf{B}\right),\end{aligned}\tag{7}$$

其中 $\mathbf{R}\in\mathbb{R}^{\mathbf{N}\times\mathbf{C}\times d_{\text{model}}}$ 是可学习向量数组，用于收集并分发各维度信息。

3）序列级依赖：为扩大感受野，近期研究对时间序列进行 token 化以捕捉序列间依赖。iTransformer [39] 引入变量嵌入 VariateEmbed，第 i 个变量 $\mathbf{X}^{(i)}$ 表示为：

$$\mathbf{H}^{(i)}=\text{VariateEmbed}(\mathbf{X}^{(i)})\tag{8}$$

其中 VariateEmbed： $\mathbb{R}^T\to\mathbb{R}^{d_{\text{model}}}$ 实例化为可训练线性投影器。基于序列全局表示，iTransformer 采用标准 Transformer 捕捉多变量时间序列的相互关联。类似地，TimeXer [158] 聚焦带外生变量的预测，分别对内生和外生变量采用分块级和序列级表示。此外，内生全局 Token 引入 TimeXer，作为中间桥梁，联合捕捉内生时间依赖及内外生变量关联。

V. 时间序列基础模型

大型语言模型（LLM）的兴起推动了时间序列基础模型（TSFM）的发展，以学习复杂的时间依赖关系并捕捉大规模数据中的潜在动态。ForecastPFN [159] 推出了首个基于新型合成数据分布训练的零样本预测模型。近年来，许多大规模时间序列模型主要利用 Transformer 架构，在数十亿至数万亿规模的数据集上预训练，以实现下游任务的强大零样本泛化能力。从技术角度看，这些模型可分为两类：从零构建的原生 TSFM 和由 LLM 适配而来的模型。

A. 原生时间序列基础模型（TSFM）

图8展示了近年发布的典型TSFM时间线，涵盖基于编码器和解码器的模型。

基于编码器的TSFM：受仅编码器深度时间序列预测模型成功的启发，研究者提出了多种基于编码器的TSFM。MOMENT [160] 是一款Transformer编码器，基于单变量数据以掩码重构目标预训练，可微调用于各类下游任务。Moirai [161] 提出多变量预训练范式，通过展平变量将所有变量视为单一序列实现。其后续版本Moirai-MoE [162] 利用稀疏专家模型以数据驱动方式建模多样化时间序列模式，实现自动令牌级专业化。此外，研究人员还在其他架构中探索TSFM。TTMs [163] 采用由多层感知机构成的轻量型架构，整合自适应补丁、多样化分辨率采样和分辨率前缀调整等技术，支持在不同分辨率数据集上预训练

Authorized licensed use limited to: XIDIAN UNIVERSITY. Downloaded on October 13,2026 at 08:55:48 UTC from IEEE Xplore. Restrictions apply.

保持最小模型容量。TiRex [164]基于xLSTM，引入新型掩码策略以保留状态跟踪能力，使预训练时间序列模型能在长预测范围内提供可靠的不确定性估计。

受仅解码器LLM进展的推动，另一系列研究采用该架构进行滚动生成。Lag-Llama [165]将时间序列滞后项作为协变量。TimesFM [166]利用大型语料库，采用带输入补丁的解码式注意力模型。Timer [154]将预测、插补和异常检测统一为生成任务，提出通用预训练Transformer。Time-MoE [167]引入稀疏混合专家架构，将训练数据扩展至3000亿个时间点。现有研究依赖预训练Transformer的固有生成能力。Sundial [168]提出基于流匹配的TimeFlow，预测下一个补丁分布，使Transformer无需离散令牌化即可训练并输出概率预测。其在1万亿个时间点上预训练，在点预测和概率预测中表现卓越且推理快速。Toto [169]面向高维可观测性，引入先进注意力机制高效分组多变量特征，在保持高精度的同时降低计算开销。

B. 大语言模型赋能的时间序列基础模型（TSFM）

基于相似的序列特性，微调预训练语言模型以赋予其时间序列分析能力，已成为极具潜力的研究方向。将大语言模型应用于时间序列分析时，需先对时间序列分词，再输入预训练模型。

GPT4TS [153] 提出统一框架，微调 GPT-2 的位置嵌入与层归一化以适配时间序列任务。LLMTime [170] 通过固定精度、缩放及编码将实值数据转为数字字符串。Chronos [171] 基于 T5 在公开及合成数据集上预训练概率预测器，经缩放量化分词后利用交叉熵损失训练。Chronos2 [172] 引入分组注意力机制，实现从单变量到通用预测的扩展。

C. 讨论

时间序列原生基础模型与大语言模型赋能的时间序列基础模型的选择取决于权衡在专用时间建模与通用推理之间。原生时间序列基础模型旨在捕捉细粒度时间模式，通过为数值数据量身定制的架构，对复杂变化提供更高保真度。因此，它们是纯数值场景的首选范式，能稳定高效地建模内在动态，提供严谨的点估计。相反，大语言模型赋能的时间序列基础模型凭借固有的语义先验和推理能力，在跨模态合成方面表现出色。这些模型尤其适用于文本描述或事件日志等上下文元数据可与时间模式对齐，或需内部世界知识辅助建模的复杂场景。因此，原生模型代表专用数值预测的前沿，而大语言模型赋能范式则为上下文感知和跨领域应用提供了通用替代方案。

VI. 时间序列库

近年来，深度时间序列方法进展显著。鉴于该领域蓬勃发展，公平基准测试成为紧迫挑战。为此，研究人员提出了DGCRN [173]、LibCity [174]、DL-Traff [175]、TS-bench [176] 和 BasicTS [14] 等基准。Autoformer [22] 提供了涵盖不同实际应用的标准长期预测基准；TimesNet [3] 则构建了包含五项主流任务的全面泛化基准。然而，现有基准存在局限：其对任务及领域的覆盖有限，限制了实际应用；且缺乏对任务类型、模型架构及基线方法的详细讨论与总结，难以有效指导高效方法的设计及推动领域发展。

为应对这些挑战，我们推出了时间序列库（TSLib），旨在公平全面地评估各类分析任务中的深度时间序列模型。如图9所示，TSLib提供统一实验框架，涵盖标准化评估协议、丰富真实数据集、先进广泛使用的模型及简化验证流程。尽管已有众多相关库，但TSLib因包含先进模型并支持广泛任务而脱颖而出，如表III所示，已获学界认可。具体而言，我们严格遵循官方代码实现了41种广泛使用的先进深度时间序列模型，用户可根据场景选择。代码见 https://github.com/thuml/Time-Series-Library。

Authorized licensed use limited to: XIDIAN UNIVERSITY. Downloaded on October 13,2026 at 08:55:48 UTC from IEEE Xplore. Restrictions apply.

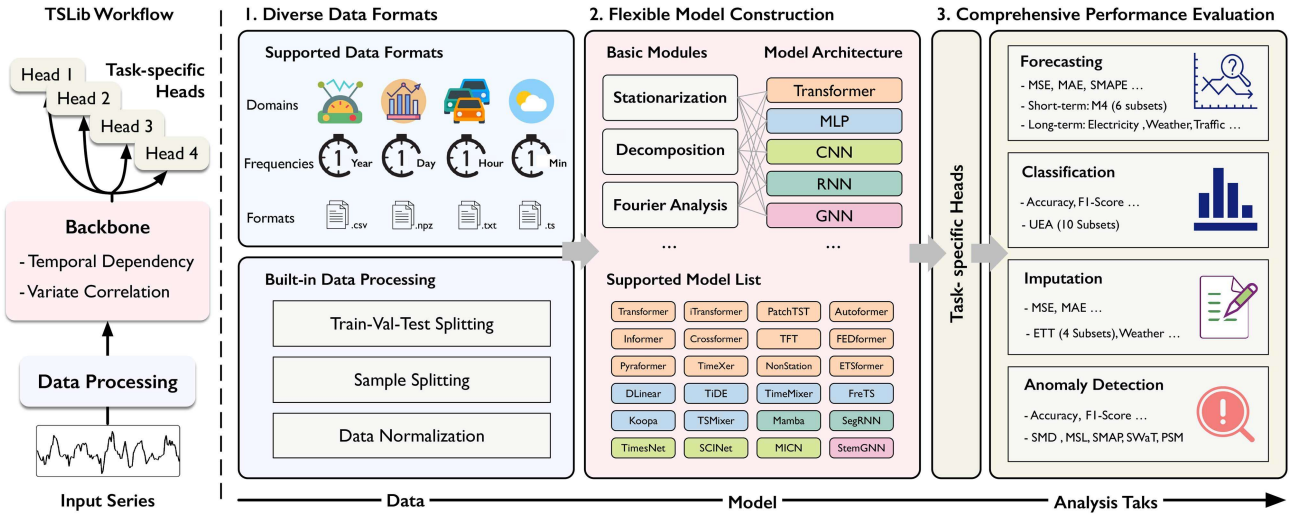


图9. 时间序列库（TSLib）的整体框架。左侧：通用任务实验的工作流程。右侧：关键特性与设计原则。

表III
TSLib与其他相关库的比较。*表示不包含深度模型。“星标”指截至2026年2月的GitHub星标数。

Library	#Models	Task	Stars
tslearn* [177]	10	Clustering, Classification, Regression	3.1k
StatsForecast* [178]	31	Forecasting, Anomaly Detection	4.7k
NeuralForecast [179]	33	Forecasting	4.0k
GluonTS [180]	25	Forecasting, Anomaly Detection	5.1k
TSLib (This Survey)	41	Forecasting, Imputation Classification, Anomaly Detection	11.6k

A. 设计与实现原则

TSLib 基于成熟的工厂模式设计，并在数据、模型与实验对象之间实现了统一接口，从而实现深度模型创建与使用的明确分离，提升了模块化程度与灵活性。通过加载不同的数据和模型对象，并结合特定任务的头部组件，TSLib 支持不同数据集与模型的共享和扩展，可轻松在各类数据集、模型及分析任务间切换。以下是其核心特性。

多样数据格式：TSLib 原生支持多种格式的广泛数据集，包括“.csv” “.npz” “.txt”等。如图 9 所示，TSLib 目前支持四个主流时间序列分析任务中 30 余种不同采样频率的数据集，全部源自能源、交通、经济、气象、医疗等真实场景。此外，TSLib 在可扩展性方面表现出色，可轻松整合不同类型的新数据源。同时，为支持后续的训练与评估，TSLib 包含大量数据处理步骤，包括时间窗口划分、数据批次生成等，其中原始数据会被划分为独立窗口，分别用于训练、验证和测试，从而简化模型训练流程并实现公平对比。这些步骤是在各类时间序列分析任务中获得精准可靠结果的必要前提。

此外，TSLib 还额外支持多种关键且有效的数据处理策略 [36]、[37]、[38]、[42]，以提升模型性能与训练效率。我们将这些多样化的设计策略封装为基础数据处理层，涵盖数据归一化、时频分解、傅里叶分析等技术。使用 TSLib 时，用户可根据自身具体需求和目标灵活选择这些策略来优化训练效果。

灵活的模型构建：如前所述，我们将深度时间序列模型的构建抽象为基础模块（第 II 节）与模型架构（第 IV 节）的组合。具体而言，我们将平稳化、分解等最常用模块与之前精心设计的模型分离开来。通过这种方式，可便捷地复现或添加使用预定义基础模块的深度模型。此外，尽管不同模型最初是为不同任务提出的，例如 Autoformer [22] 用于预测，TimesNet [3] 用于更通用的任务，但遵循本综述中“以模型为中心”的原则，我们将各类分析任务统一为带有特定领域头部组件的表示学习任务，从而实现对不同主干模型的通用任务评估。

全面的性能评估：基于上述两个核心特性，TSLib 可自然地支持在大量数据集上对不同模型在各类任务中的表现进行评估，从而构建全面的基准。具体而言，在 TSLib 中，我们提供四个主流时间序列分析任务的评估：分类、填补、预测和异常检测。每个任务都包含特定的评估指标，可实现对模型性能的全面评估。需要注意的是，我们遵循以往的惯例，将预测任务进一步区分为长期和短期任务，划分依据为预测时域。

Authorized licensed use limited to: XIDIAN UNIVERSITY. Downloaded on October 13,2026 at 08:55:48 UTC from IEEE Xplore. Restrictions apply.

B. 评估协议与指标

为实现公平全面的模型对比，TSLib 参照 [3] 为四项主流时间序列分析任务提供了标准化评估协议。具体而言，不同模型基于相同的训练策略和测试集进行训练与测试，以避免配置不一致问题，确保严谨对比。

参照已有研究，长期预测与插补任务采用均方误差（MSE）和平均绝对误差（MAE）。短期预测使用对称平均绝对百分比误差（SMAPE）和平均绝对比例误差（MASE），这些指标聚焦绝对误差以降低异常值影响，为不同数据集和方法提供可靠评估。时间序列分类任务采用分类准确率。异常检测使用 F1 分数验证识别效果；该分数均衡精确率与召回率，全面评估分类器性能，尤其适用于类别不平衡的异常情况。

C. 支持的数据集

TSLib 原生支持多种广泛使用的数据集，涵盖不同样本量、变量数及领域任务。任务与数据集对应关系如图 9 所示。因均为常用数据集，此处仅简要介绍，详情见文献 [3]。

预测是过往研究中最广泛探索的任务之一，提供了丰富的实验数据集。如设计原则所述，我们按预测时域将其分为长期和短期两类。长期时间序列预测方面，TSLib 包含 9 个数据集，涵盖电力变压器温度（ETT，含 4 个子集）[21]、电力、天气、交通、汇率及疾病 [22]。短期预测任务则纳入了 M4 数据集 [181]，该数据集包含 6 个采样频率与领域各异的子数据集。

填补：故障导致时间序列数据存在缺失，构成分析挑战。因难以获取真实值，我们利用电力变压器温度（ETT，含4个子集）[21]、电力及天气数据，通过随机掩盖部分时间步长构建缺失场景。

异常检测：识别时间序列中的异常模式，这些模式可能指示需关注的关键事件、故障或离群值。TSLib 支持主流数据集，如服务器机器数据集（SMD）[182]、火星科学实验室漫游车（MSL）[183]、土壤湿度主动被动卫星

表 IV
时间序列库中每项时间序列分析任务的默认训练配置。LR* 表示初始学习率。

Task	LR*	Loss	BatchSize	Epochs
Long-term Forecasting	10^{-4}	MSE	32	10
Short-term Forecasting	10^{-3}	SMAPE	16	10
Imputation	10^{-3}	MSE	16	10
Classification	10^{-3}	Cross Entropy	16	100
Anomaly Detection	10^{-4}	MSE	128	10

（SMAP）[183]、安全水处理（SWaT）[184] 及汇总服务器指标（PSM）[185]，均源自多种工业场景。

分类：我们从 UEA 时间序列分类档案 [186] 选取 10 个多变量数据集，用于测试序列级分类任务。这些数据集涵盖手势、动作、音频识别及心跳医学诊断等实际任务。我们按 [187] 描述对数据集进行预处理。

D. 默认实验设置

此处提供TSLib各任务的实验设置。长期与零样本预测中，ILI数据集回溯长度36，预测长度 $\{24, 36, 48, 60\}$；其他数据集回溯96，预测 $\{96, 192, 336, 720\}$。短期预测中，年、季、月、周、日、小时数据预测长度分别为 $\{6, 8, 18, 13, 14, 48\}$。分类任务将高维时间序列划分为多类。填补任务按 $\{12.5\%, 25\%, 37.5\%, 50\%\}$ 随机掩码时间点。异常检测中，重建是无监督逐点表示学习经典任务，其误差为天然异常准则。故以深度时间序列模型为重建基础，共享该误差作为所有实验的异常准则。

实现细节：本文实验基于PyTorch在NVIDIA A100 GPU上运行，采用Adam优化器。我们全面评估了各模型在时间序列分析任务中的性能。为确保最优表现及公平比较，遵循[188]对每种架构进行超参数搜索。具体而言，我们在 $\left[2^4, 2^9\right]$ 范围内搜索隐藏层数 $L \in \{2, 3, 4\}$ 和维度 d_{model}。针对各任务，TSLib采用任务特定且模型共享的训练配置（含学习率、损失函数、批量大小和轮数），详见表IV。

回溯搜索设置：长期预测中，模型性能高度依赖输入序列的历史长度。因各论文回溯长度不一，我们进一步开展

Authorized licensed use limited to: XIDIAN UNIVERSITY. Downloaded on October 13,2026 at 08:55:48 UTC from IEEE Xplore. Restrictions apply.

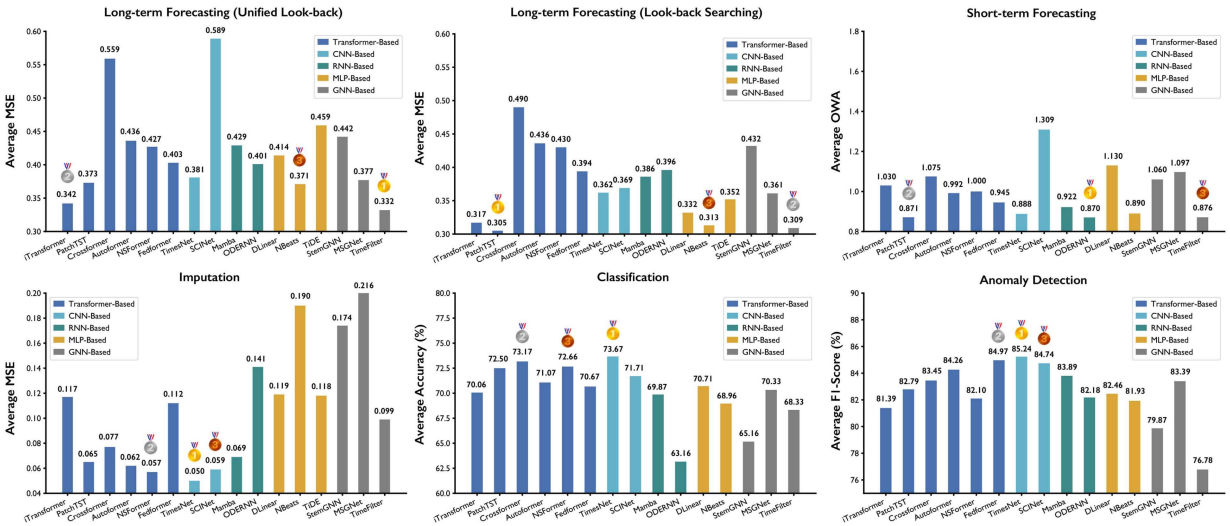


图10. 基于时间序列库的模型性能比较。完整结果是对TSLib支持的各类数据集在四项主流分析任务上的平均值。在分类和异常检测任务中，更高的准确率或F1分数表示模型性能更好。相反，对于其他任务，更低的平均MSE或MAE则表明模型效果更优。各时间分析任务的前三名模型在排行榜上突出显示，同时标注了各时间序列分析任务的最优模型。

了一组名为“回溯搜索”的额外实验，以确保公平可靠的比较。在这些实验中，我们遵循[188]在 $\{96, 192, 336, 512\}$ 中系统搜索输入长度，并对每个模型架构进行广泛的超参数搜索，以达到其最优性能。这种方法使我们能够评估每个模型可实现的最大性能，同时确保报告的结果准确反映其能力，并便于在不同模型之间进行公平比较。

E. 结果与分析

为探究主流时间序列分析任务中各类方法的优势与局限性，我们从TSLib中选取16个代表性深度模型和6个时间序列基础模型进行对比。这些模型涵盖5种流行的深度模型架构及任务，包括长短期预测、分类、插补和异常检测。

基线模型：为探究不同架构的有效性，我们选取了多个先进Transformer模型进行对比，包括iTransformer [39]、PatchTST [23]、Autoformer [22]、非平稳Transformer（平稳）[38]和FEDformer [81]（见图10）。此外，将TimesNet [3]和SCINet [127]视为CNN模型；RNN模型涵盖Mamba [116]和ODERNN [118]；GNN基线包括支持数据驱动建图的StemGNN [85]、MSGNet [189]和TimeFilter [190]。MLP模型测试了DLinear [49]、N-BEATS [24]和TiDE [94]。因TiDE [94]依赖时间戳，仅用于长期预测任务。

我们还纳入了6个主流时间序列基础模型，即Moirai-2.0 [162]、TimesFM-2.5 [166]、Time-MoE [167]、TiRex [164]、Sundial [168]和Chronos-2 [172]，以评估它们的零样本预测性能。由于TimesFM和其他TSFMs在预训练过程中泄露了ECL、Weather和Traffic数据集，因此评估仅限于ETT数据集。

定量结果：如图10所示，基于Transformer的模型，尤其是iTransformer [39]和PatchTST [23]，在各类任务中均实现了当前最优性能，尤其在长期预测任务中表现突出，这凸显了专用嵌入机制和注意力机制在释放其架构能力方面的关键作用。基于GNN的模型也展现出具有竞争力的效能，其中TimeFilter [190]和MSGNet [189]分别在预测和异常检测任务中表现出色，而TimesNet [3]作为通用任务建模的里程碑脱颖而出。从架构角度来看，结果显示出明显的权衡：基于MLP的模型在预测任务中展现出惊人的效率，但在高级表示学习方面表现不佳；而基于CNN的架构在非预测任务中展现出更全面的能力。尽管GNN能有效捕捉序列间的相关性，但它们通常缺乏领先CNN框架所具备的通用任务优势。与此同时，基于RNN的模型在短期任务中仍然适用，但在长期预测任务中表现有限。总体而言，Transformer在基准测试中的持续优势凸显了其强大的建模能力，以及作为高级时间序列分析统一骨干的潜力。

在TSLib协议下，我们还对不同输入长度下时间序列基础模型的零样本预测性能进行了对比。具体而言，我们将输入长度从传统的96增加到

Authorized licensed use limited to: XIDIAN UNIVERSITY. Downloaded on October 13,2026 at 08:55:48 UTC from IEEE Xplore. Restrictions apply.

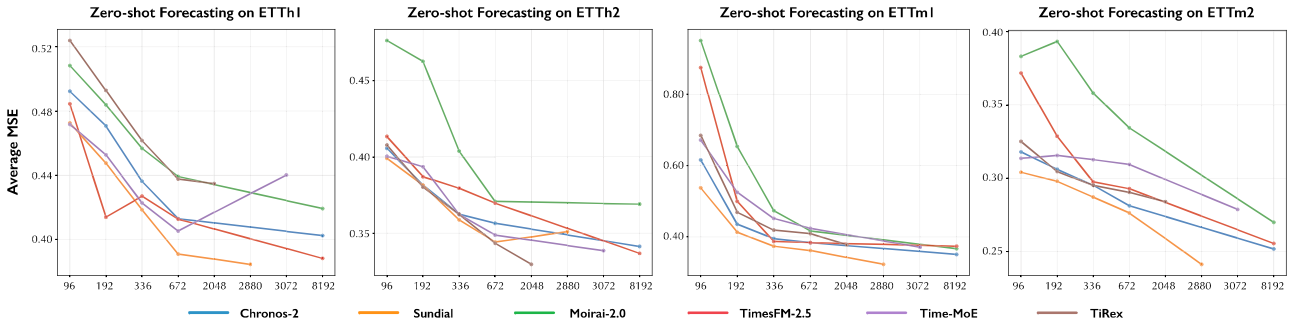


图11 不同TSFMs在不同输入长度下的零样本预测性能。对于Moirai和TimesFM，其最大支持上下文长度超过可用数据集大小，我们将它们的输入长度与Chronos-2的最大容量对齐，以确保对比的一致性和公平性。

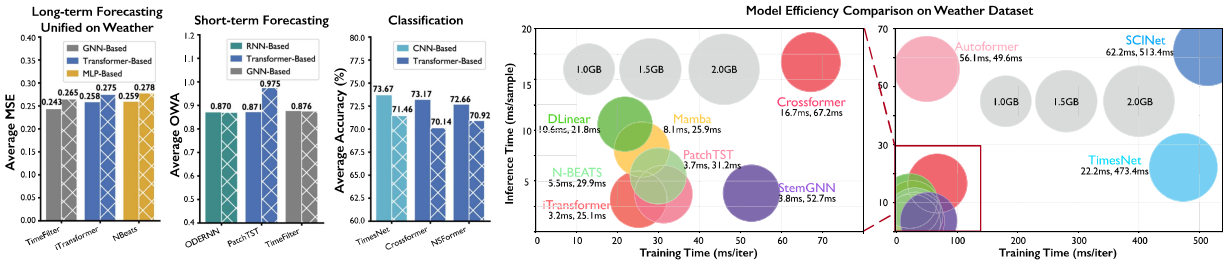


图12 （左）深度时间序列模型的鲁棒性分析，带交叉阴影的条形表示含噪数据下的性能。（右）在Weather数据集上测试的长期预测模型效率。

各模型支持的最大上下文长度。图11报告了ETT数据集上四个预测视野 $\{96, 192, 336, 720\}$ 的平均结果。总体而言，增加输入上下文长度通常会提升零样本性能，凸显了TSFMs处理长上下文信息的有效性。值得注意的是，我们观察到输入长度为2880的Sundial的性能超过了输入长度为8192的其他TSFMs。这表明过长的输入可能会引入无关信息或随机噪声，从而掩盖有意义的时间模式。这些发现表明，最优的零样本性能由模型的架构能力和输入数据的固有可预测性共同决定，凸显了选择合适的回溯窗口以平衡上下文丰富度和数据质量的重要性。

定性分析：我们还提供了效率比较，以深入洞察不同方法的实用性和可行性。具体而言，我们在所有模型采用统一超参数设置的情况下，测量了每个模型在执行长期预测时的训练时间、推理时间和内存占用。如图 12（右侧）所示，可以观察到标记化设计会影响模型效率，其中采用逐点标记的 Autoformer [22] 比采用逐块标记的 PatchTST [23] 和采用序列级标记的 iTransformer [39] 更慢。此外，基于 CNN 的模型（如 SCINet [127] 和 TimesNet [3]）由于需要采用多样化的卷积核来捕捉复杂的时间模式，其耗时远超其他架构。相比之下，基于 MLP 的模型以及最新的 Mamba 模型凭借更高的效率脱颖而出，其结构更加简洁和轻量架构使其特别适合计算资源有限的场景。上述发现凸显了模型效率与预测性能之间的固有权衡，这也可为资源受限场景下的模型选择提供重要指导。

为进一步评估所研究模型的实际适用性，我们对这些深度模型开展了鲁棒性分析。鉴于真实世界时间序列数据存在固有复杂性与噪声，我们向输入数据中系统性地添加了随机白噪声，以严格评估模型的鲁棒性。具体而言，我们聚焦于三项代表性分析任务：长期预测、短期预测与分类，为每项任务选取性能排名前三的深度模型。如图12（左）所示，噪声的引入仅导致大多数模型出现轻微的性能下降。这种相对稳定性表明，这些模型具备固有鲁棒性，证实了它们在实际场景中的可行性与可靠性。

VII. 未来方向

本节探讨时间序列分析的前景研究方向。

A. 时间序列预训练

预训练-微调范式已广泛应用于语言[16]、[191]和视觉[192]、[193]领域，该范式通过无监督预训练构建基础能力，再进行任务特定微调。鉴于标签稀缺，自监督预训练[193]已成为一种强大策略

Authorized licensed use limited to: XIDIAN UNIVERSITY. Downloaded on October 13,2026 at 08:55:48 UTC from IEEE Xplore. Restrictions apply.

适用于时间序列，主要分为对比学习[194]和掩码建模[16]、[195]两类。

对比学习通过对比相似对与不相似对来规范表示[194]、[196]。为解决SimCLR [196]等基于计算机视觉的方法在时序建模中的局限性，研究人员提出了特定方法：CPC [197]通过预测编码捕捉时序结构，TS2Vec [198]采用分层实例级和补丁级损失，TS-TCC [199]引入时间序列特定增强方法。针对长期依赖关系，CoST [200]学习解耦的季节-趋势表示。掩码建模是一种基于重构的方法，可从周围上下文预测掩码令牌[16]、[195]、[201]。遵循BERT范式[16]，TST [202]首次将其应用于多变量时间序列。后续改进聚焦于分层和结构优化：PatchTST [23]在补丁级别运行，HiMTM [203]采用分层框架处理多尺度特征。此外，SimMTM [204]通过邻域聚合整合流形学习，TimeSiam [205]采用带非对称掩码的孪生网络以捕捉内在时序相关性。

B. 实际应用

1) 概率预测：概率预测是深度时间序列模型实际应用中的关键进展，尤其有助于辅助决策。与此前被广泛研究的确定性预测不同，概率预测可输出未来潜在结果的分布，帮助利益相关方评估风险、计算置信区间，并在不确定性下做出可靠决策。大多数现有概率预测模型依赖预定义的概率分布，旨在预测未来分布的参数。尽管这些方法已取得显著成功，但对预定义分布的依赖可能会限制其表征复杂且异构的现实世界不确定性的能力。因此，准确建模并表征此类复杂性，以生成更灵活、可靠的概率预测，仍是未来研究的关键且活跃领域。

2) 处理极长序列：深度时间序列模型在各类下游任务中表现出色，但其对更长时间序列数据的适用性常受限于可扩展性和高计算复杂度。在工业时间序列分析中，高频采样会产生冗长的历史数据，阻碍了高级深度模型的实际应用。现有方法通常采用分块技术来处理长序列，当输入长度增加时，可相应增大分块长度以降低计算复杂度。然而，模型性能与分块长度密切相关；因此，仅通过增大分块尺寸来降低复杂度可能会损害模型能力。因此，解决深度模型在处理更长时间序列时的局限性，有望成为一个有前景的研究方向。

3) 利用外生变量：时间序列变化常受外部因素影响，纳入外生变量对全面理解至关重要。外生变量在时间序列预测任务中被广泛讨论，将其纳入模型可在建模时间序列数据时进行统一训练，无需单独分析。然而，在实际应用中，与多变量时间序列分析不同，主变量和协变量通常处于不同位置。鉴于外生变量在实际应用中的关键作用，有必要探索一个统一框架，用于建模内生变量与外生变量之间的关系，从而更全面地理解不同变量之间的相互关联和因果关系，提升模型性能的可靠性与可解释性。

4) 处理异构数据：对异构时间序列进行建模仍是一项重大挑战。这类数据具有多样特征，包括不同采样率、不规则性和不同长度尺度，这使得有效捕捉潜在模式变得复杂。此外，当前深度学习模型对固定大小输入的要求，本质上限制了其处理这种动态、可变长度特性的能力。解决这些问题需要创新方法，既能适应单个时间序列的独特特征，又能捕捉多个序列的总体模式。这包括开发新的特征提取技术，探索适用于可变长度输入的替代架构。在这个相对未被深入研究的领域开展进一步研究，有望为金融、医疗保健等领域带来重大进展，加深对数据的理解并提升预测分析能力。

5) 处理复杂扰动数据：模型的稳健性是深度时间序列模型在实际应用中可靠部署的关键。在实践中，数据常受到超出典型随机波动的复杂扰动，包括脉冲尖峰、非平稳噪声和不规则缺失值。此类扰动可能源于传感器不稳定、环境变化或间歇性传输故障，形成高度动态且不可预测的数据流。这些复杂扰动的存在常导致瞬时失真，掩盖潜在的时间模式。因此，应对这些具有挑战性的数据条件，需要开发专门处理复杂扰动的模块，这是一个关键且有前景的研究方向。该领域的进展不仅会提升时间序列分析的基础稳定性，还能为安全关键型工业系统提供更可靠的决策支持。

VIII. 结论

在本综述中，我们对时间序列分析领域的深度模型进行了系统性回顾，并引入时间序列库（TSLib）作为各类任务中深度时间序列模型的公平基准。与以往聚焦于特定分析任务或模型架构的综述不同，本文对现有时间序列分析深度模型进行了全面综述与概述，涵盖预测、分类、

Authorized licensed use limited to: XIDIAN UNIVERSITY. Downloaded on October 13,2026 at 08:55:48 UTC from IEEE Xplore. Restrictions apply.

填补及异常检测。通过将基础模块与复杂多样的深度时间序列模型相分离，我们成功揭示了当前研究的基础设计原则，形成了富有启发性的以模型为中心的视角。此外，基于TSLib（其支持灵活且全面的模型评估），我们开展了大量实验，为模型设计与实际应用提供了洞见。凭借清晰的总结、丰富的实验及深入的讨论，我们相信本综述与TSLib能够为未来深度时间序列模型的研究提供指导并发挥作用。

参考文献

[1] G. E. Box, G. M. Jenkins, G. C. Reinsel, and G. M. Ljung, *Time Series Analysis: Forecasting and Control*. Hoboken, NJ, USA: Wiley, 2015.

[2] J. D. Hamilton, *Time Series Analysis*. Princeton, NJ, USA: Princeton Univ. Press, 2020.

[3] H. Wu, T. Hu, Y. Liu, H. Zhou, J. Wang, and M. Long, "TimesNet: Temporal 2D-variation modeling for general time series analysis," in *Proc. Int. Conf. Learn. Representations*, 2023, pp. 6423–6445.

[4] K. Jin, J. Wi, E. Lee, S. Kang, S. Kim, and Y. Kim, "TrafficBERT: Pre-trained model with large-scale data for long-range traffic flow forecasting," *Expert Syst Appl.*, vol. 186, 2021, Art. no. 115738.

[5] J. Xu, H. Wu, J. Wang, and M. Long, "Anomaly transformer: Time series anomaly detection with association discrepancy," in *Proc. Int. Conf. Learn. Representations*, 2022, pp. 5203–5222.

[6] H. Wu, H. Zhou, M. Long, and J. Wang, "Interpretable weather forecasting for worldwide stations with a unified deep model," *Nature Mach. Intell.*, vol. 5, pp. 602–611, 2023.

[7] L. H. Koopmans, *The Spectral Analysis of Time Series*. New York, NY, USA: Academic, 1995.

[8] H. I. Fawaz, G. Forestier, J. Weber, L. Idoumghar, and P.-A. Muller, "Deep learning for time series classification: A review," *Data Mining Knowl. Discov.*, vol. 33, pp. 917–963, 2019.

[9] M. Braei and S. Wagner, "Anomaly detection in univariate time-series: A survey on the state-of-the-art," 2020, *arXiv:2004.00433*.

[10] J. F. Torres, D. Hadjout, A. Sebaa, F. Martıńez-Álvarez, and A. Troncoso, "Deep learning for time series forecasting: A survey," *Big Data*, vol. 9, pp. 3–21, 2021.

[11] A. Blázquez-Garcıá, A. Conde, U. Mori, and J. A. Lozano, "A review on outlier/anomaly detection in time series data," *ACM Comput. Surv.*, vol. 54, 2021, Art. no. 56.

[12] Q. Wen et al., "Transformers in time series: A survey," in *Proc. Int. Joint Conf. Artif. Intell.*, 2023, Art. no. 759.

[13] M. Jin et al., "A survey on graph neural networks for time series: Forecasting, classification, imputation, and anomaly detection," *IEEE Trans. Pattern Anal. Mach. Intell.*, vol. 46, no. 12, pp. 10466–10485, Dec. 2024.

[14] Z. Shao et al., "Exploring progress in multivariate time series forecasting: Comprehensive benchmarking and heterogeneity analysis," *IEEE Trans. Knowl. Data Eng.*, vol. 37, no. 1, pp. 291–305, Jan. 2025.

[15] X. Qiu et al., "TFB: Towards comprehensive and fair benchmarking of time series forecasting methods," *Proc. VLDB Endowment*, vol. 17, pp. 2363–2377, 2024.

[16] J. Devlin, M.-W. Chang, K. Lee, and K. Toutanova, "BERT: Pre-training of deep bidirectional transformers for language understanding," in *Proc. Conf. North Amer. Chapter Assoc. Comput. Linguistics: Hum. Lang. Technol.*, 2019, pp. 4171–4186.

[17] J. Achiam et al., "GPT-4 technical report," 2023, *arXiv:2303.08774*.

[18] K. He, X. Zhang, S. Ren, and J. Sun, "Deep residual learning for image recognition," in *Proc. IEEE Conf. Comput. Vis. Pattern Recognit.*, 2016, pp. 770–778.

[19] A. Dosovitskiy et al., "An image is worth 16 × 16 words: Transformers for image recognition at scale," in *Proc. Int. Conf. Learn. Representations*, 2022, pp. 611–631.

[20] S. Zhang, L. Yao, A. Sun, and Y. Tay, "Deep learning based recommender system: A survey and new perspectives," *ACM Comput. Surv.*, vol. 52, 2019, Art. no. 5.

[21] H. Zhou et al., "Informer: Beyond efficient transformer for long sequence time-series forecasting," in *Proc. AAAI Conf. Artif. Intell.*, 2021, pp. 11106–11115.

[22] H. Wu, J. Xu, J. Wang, and M. Long, "Autoformer: Decomposition transformers with auto-correlation for long-term series forecasting," in *Proc. Int. Conf. Neural Inf. Process. Syst.*, 2021, pp. 22419–22430.

[23] Y. Nie, N. H. Nguyen, P. Sinthong, and J. Kalagnanam, "A time series is worth 64 words: Long-term forecasting with transformers," in *Proc. Int. Conf. Learn. Representations*, 2023, pp. 33132–33155.

[24] B. N. Oreshkin, D. Carpov, N. Chapados, and Y. Bengio, "N-BEATS: Neural basis expansion analysis for interpretable time series forecasting," in *Proc. Int. Conf. Learn. Representations*, 2020, pp. 1–38.

[25] A. van den Oord, N. Kalchbrenner, and K. Kavukcuoglu, "Pixel recurrent neural networks," in *Proc. Int. Conf. Mach. Learn.*, 2016, pp. 1747–1756.

[26] S. Oprea et al., "A review on deep learning techniques for video prediction," *IEEE Trans. Pattern Anal. Mach. Intell.*, vol. 44, no. 6, pp. 2806–2826, Jun. 2022.

[27] J. H. Stock and M. W. Watson, "Vector autoregressions," *J. Econ. Perspectives*, vol. 15, pp. 101–115, 2001.

[28] A. S. Weigend, *Time Series Prediction: Forecasting the Future and Understanding the Past*. Evanston, IL, USA: Routledge, 2018.

[29] G. P. Zhang, "Time series forecasting using a hybrid ARIMA and neural network model," *Neurocomputing*, vol. 50, pp. 159–175, 2003.

[30] C. Fang and C. Wang, "Time series data imputation: A survey on deep learning approaches," 2020, *arXiv:2011.11347*.

[31] Y. Luo et al., "Multivariate time series imputation with generative adversarial networks," in *Proc. Int. Conf. Neural Inf. Process. Syst.*, 2018, pp. 1603–1614.

[32] S. Moritz and T. Bartz-Beielstein, "imputeTS: Time series missing value imputation in R," *R J.*, vol. 9, pp. 207–2018, 2017.

[33] B. Zhao, H. Lu, S. Chen, J. Liu, and D. Wu, "Convolutional neural networks for time series classification," *J. Syst. Eng. Electron.*, vol. 28, no. 1, pp. 162–169, Feb. 2017.

[34] N. Laptev, S. Amizadeh, and I. Flint, "Generic and scalable framework for automated time-series anomaly detection," in *Proc. ACM SIGKDD Int. Conf. Knowl. Discov. Data Mining*, 2015, pp. 1939–1947.

[35] D. Ulyanov, A. Vedaldi, and V. Lempitsky, "Instance normalization: The missing ingredient for fast stylization," 2016, *arXiv:1607.08022*.

[36] N. Passalis, A. Tefas, J. Kanniainen, M. Gabbouj, and A. Iosifidis, "Deep adaptive input normalization for time series forecasting," *IEEE Trans. Neural Netw. Learn. Syst.*, vol. 31, no. 9, pp. 3760–3765, Sep. 2020.

[37] T. Kim, J. Kim, Y. Tae, C. Park, J.-H. Choi, and J. Choo, "Reversible instance normalization for accurate time-series forecasting against distribution shift," in *Proc. Int. Conf. Learn. Representations*, 2022, pp. 16644–16668.

[38] Y. Liu, H. Wu, J. Wang, and M. Long, "Non-stationary transformers: Exploring the stationarity in time series forecasting," in *Proc. Int. Conf. Neural Inf. Process. Syst.*, 2022, Art. no. 718.

[39] Y. Liu et al., "iTransformer: Inverted transformers are effective for time series forecasting," in *Proc. Int. Conf. Learn. Representations*, 2024, pp. 4004–4028.

[40] J. Gao, W. Hu, and Y. Chen, "Client: Cross-variable linear integrated enhanced transformer for multivariate long-term time series forecasting," *AI Open*, vol. 6, pp. 93–107, 2025.

[41] Z. Liu et al., "Adaptive normalization for non-stationary time series forecasting: A temporal slice perspective," in *Proc. Int. Conf. Neural Inf. Process. Syst.*, 2024, pp. 14273–14292.

[42] R. B. Cleveland, W. S. Cleveland, J. E. McRae, and I. Terpenning, "STL: A seasonal-trend decomposition," *J. Official Statist.*, vol. 6, pp. 3–73, 1990.

[43] M. Kendall, *Time-Series*, 2nd ed. London: Griffin, 1976.

[44] C. RB, "STL: A seasonal-trend decomposition procedure based on loess," *J. Official Statist.*, vol. 6, pp. 3–73, 1990.

[45] E. B. Dagum and S. Bianconcini, *Seasonal Adjustment Methods and Real Time Trend-Cycle Estimation*. Berlin, Germany: Springer, 2016.

[46] Q. Wen, J. Gao, X. Song, L. Sun, H. Xu, and S. Zhu, "RobustSTL: A robust seasonal-trend decomposition algorithm for long time series," in *Proc. AAAI Conf. Artif. Intell.*, 2019, pp. 5409–5416.

[47] A. M. De Livera, R. J. Hyndman, and R. D. Snyder, "Forecasting time series with complex seasonal patterns using exponential smoothing," *J. Amer. Statist. Assoc.*, vol. 106, pp. 1513–1527, 2011.

[48] S. J. Taylor and B. Letham, "Forecasting at scale," *Amer. Statistician*, vol. 72, pp. 37–45, 2018.

[49] A. Zeng, M. Chen, L. Zhang, and Q. Xu, "Are transformers effective for time series forecasting?," in *Proc. AAAI Conf. Artif. Intell.*, 2023, pp. 11121–11128.

Authorized licensed use limited to: XIDIAN UNIVERSITY. Downloaded on October 13,2026 at 08:55:48 UTC from IEEE Xplore. Restrictions apply.

[50] H. Cao, Z. Huang, T. Yao, J. Wang, H. He, and Y. Wang, "InParformer: Evolutionary decomposition transformers with interactive parallel attention for long-term time series forecasting," in *Proc. AAAI Conf. Artif. Intell.*, 2023, pp. 6906–6915.
[51] D. Du, B. Su, and Z. Wei, "Preformer: Predictive transformer with multi-scale segment-wise correlations for long-term time series forecasting," in *Proc. Int. Conf. Acoust. Speech Signal Process.*, 2023, pp. 1–5.
[52] D. Cao et al., "TEMPO: Prompt-based generative pre-trained transformer for time series forecasting," in *Proc. Int. Conf. Learn. Representations*, 2024, pp. 54813–54845.
[53] C. Challu, K. G. Olivares, B. N. Oreshkin, F. G. Ramirez, M. M. Canseco, and A. Dubrawski, "NHITS: Neural hierarchical interpolation for time series forecasting," in *Proc. AAAI Conf. Artif. Intell.*, 2023, pp. 6989–6997.
[54] W. Fan et al., "DEPTS: Deep expansion learning for periodic time series forecasting," in *Proc. Int. Conf. Learn. Representations*, 2022, pp. 8520–8543.
[55] W. Fan, Y. Fu, S. Zheng, J. Bian, Y. Zhou, and H. Xiong, "DEWP: Deep expansion learning for wind power forecasting," *ACM Trans. Knowl. Discov. Data*, vol. 18, 2024, Art. no. 71.
[56] L. Xiong, X. Chen, T.-K. Huang, J. Schneider, and J. G. Carbonell, "Temporal collaborative filtering with Bayesian probabilistic tensor factorization," in *Proc. SIAM Int. Conf. Data Mining*, 2010, pp. 211–222.
[57] H.-F. Yu, N. Rao, and I. S. Dhillon, "Temporal regularized matrix factorization for high-dimensional time series prediction," in *Proc. Int. Conf. Neural Inf. Process. Syst.*, 2016, pp. 847–855.
[58] K. Takeuchi, H. Kashima, and N. Ueda, "Autoregressive tensor factorization for spatio-temporal predictions," in *Proc. IEEE Int. Conf. Data Mining*, 2017, pp. 1105–1110.
[59] X. Chen, C. Zhang, X.-L. Zhao, N. Saunier, and L. Sun, "Nonstationary temporal matrix factorization for multivariate time series forecasting," 2022, *arXiv:2203.10651*.
[60] X. Chen and L. Sun, "Bayesian temporal factorization for multidimensional time series prediction," *IEEE Trans. Pattern Anal. Mach. Intell.*, vol. 44, no. 9, pp. 4659–4673, Sep. 2022.
[61] R. Sen, H.-F. Yu, and I. S. Dhillon, "Think globally, act locally: A deep neural network approach to high-dimensional time series forecasting," in *Proc. Int. Conf. Neural Inf. Process. Syst.*, 2019, Art. no. 435.
[62] J.-M. Yang, Z.-R. Peng, and L. Lin, "Real-time spatiotemporal prediction and imputation of traffic status based on LSTM and graph Laplacian regularized matrix factorization," *Transp. Res. Part C, Emerg. Technol.*, vol. 129, 2021, Art. no. 103228.
[63] D. Cai, X. He, J. Han, and T. S. Huang, "Graph regularized nonnegative matrix factorization for data representation," *IEEE Trans. Pattern Anal. Mach. Intell.*, vol. 33, no. 8, pp. 1548–1560, Aug. 2011.
[64] I. N. Sneddon, *Fourier Transforms*. North Chelmsford, MA, USA: Courier Corporation, 1995.
[65] J. W. Goodman, *Introduction to Fourier Optics*. Greenwood Village, CO, USA: Roberts and Company Publishers, 2005.
[66] P. Bloomfield, *Fourier Analysis of Time Series: An Introduction*. Hoboken, NJ, USA: Wiley, 2004.
[67] K. Samiee, P. Kovacs, and M. Gabbouj, "Epileptic seizure classification of EEG time-series using rational discrete short-time fourier transform," *IEEE Trans. Biomed. Eng.*, vol. 62, no. 2, pp. 541–552, Feb. 2015.
[68] E. O. Brigham, *The Fast Fourier Transform and Its Applications*. Englewood Cliffs, NJ, USA: Prentice-Hall, 1988.
[69] Y. Meyer, *Wavelets and Operators*, vol. 1. Cambridge, U.K.: Cambridge Univ. Press, 1992.
[70] J. Wang, Z. Wang, J. Li, and J. Wu, "Multilevel wavelet decomposition network for interpretable time series analysis," in *Proc. ACM SIGKDD Int. Conf. Knowl. Discov. Data Mining*, 2018, pp. 2437–2446.
[71] S. Yao et al., "STFNets: Learning sensing signals from the time-frequency perspective with short-time fourier neural networks," in *Proc. World Wide Web Conf.*, 2019, pp. 2192–2202.
[72] M. Rhif, A. Ben Abbes, I. R. Farah, B. Martıńez, and Y. Sang, "Wavelet transform application for/in non-stationary time-series analysis: A review," *Appl. Sci.*, vol. 9, 2019, Art. no. 1345.
[73] L. Minhao et al., "T-WaveNet: A tree-structured wavelet neural network for time series signal analysis," in *Proc. Int. Conf. Learn. Representations*, 2022, pp. 12961–12972.
[74] L. Yang and S. Hong, "Unsupervised time-series representation learning with iterative bilinear temporal-spectral fusion," in *Proc. Int. Conf. Mach. Learn.*, 2022, pp. 25038–25054.
[75] J. Wang, C. Yang, X. Jiang, and J. Wu, "When: A wavelet-dtw hybrid attention network for heterogeneous time series analysis," in *Proc. ACM SIGKDD Int. Conf. Knowl. Discov. Data Mining*, 2023.
[76] F. Yang, X. Li, M. Wang, H. Zang, W. Pang, and M. Wang, "Waveform: Graph enhanced wavelet learning for long sequence forecasting of multivariate time series," in *Proc. AAAI Conf. Artif. Intell.*, 2023, pp. 10754–10761.
[77] K. Yi et al., "A survey on deep learning based time series analysis with frequency transformation," in *Proc. ACM SIGKDD Int. Conf. Knowl. Discov. Data Mining*, 2025, pp. 6206–6215.
[78] T. Dai et al., "Periodicity decoupling framework for long-term series forecasting," in *Proc. Int. Conf. Learn. Representations*, 2024, pp. 13990–14001.
[79] T. Zhou et al., "FiLM: Frequency improved legendre memory model for long-term time series forecasting," in *Proc. Int. Conf. Neural Inf. Process. Syst.*, 2022, Art. no. 921.
[80] Z. Xu, A. Zeng, and Q. Xu, "FITS: Modeling time series with $10k$ parameters," in *Proc. Int. Conf. Learn. Representations*, 2024, pp. 29143–29166.
[81] T. Zhou, Z. Ma, Q. Wen, X. Wang, L. Sun, and R. Jin, "FEDformer: Frequency enhanced decomposed transformer for long-term series forecasting," in *Proc. Int. Conf. Mach. Learn.*, 2022, pp. 27268–27286.
[82] N. Wiener, "Generalized harmonic analysis," *Acta Mathematica*, vol. 55, pp. 117–2581930.
[83] Z. Yang, W. Yan, X. Huang, and L. Mei, "Adaptive temporal-frequency network for time-series forecasting," *IEEE Trans. Knowl. Data Eng.*, vol. 34, no. 4, pp. 1576–1587, Apr. 2022.
[84] C. Zhang, T. Zhou, Q. Wen, and L. Sun, "TFAD: A decomposition time series anomaly detection architecture with time-frequency analysis," in *Proc. 31st ACM Int. Conf. Inf. Knowl. Manage.*, 2022, pp. 2497–2507.
[85] D. Cao et al., "Spectral temporal graph neural network for multivariate time-series forecasting," in *Proc. Int. Conf. Neural Inf. Process. Syst.*, 2020, Art. no. 1491.
[86] K. Yi et al., "Edge-varying fourier graph networks for multivariate time series forecasting," 2022, *arXiv:2210.03093*.
[87] K. Yi et al., "Frequency-domain MLPs are more effective learners in time series forecasting," in *Proc. Int. Conf. Neural Inf. Process. Syst.*, 2024, Art. no. 3349.
[88] Z. Wang et al., "Revisiting VAE for unsupervised time series anomaly detection: A frequency perspective," in *Proc. ACM Web Conf.*, 2024, pp. 3096–3105.
[89] E. Eldele, M. Ragab, Z. Chen, M. Wu, and X. Li, "TSLANet: Rethinking transformers for time series representation learning," in *Proc. Int. Conf. Mach. Learn.*, 2024, pp. 12409–12428.
[90] J. Crabbé, N. Huynh, J. Stanczuk, and M. van der Schaar, "Time series diffusion in the frequency domain," in *Proc. Int. Conf. Mach. Learn.*, 2024, pp. 9407–9438.
[91] K. G. Olivares, C. Challu, G. Marcjasz, R. Weron, and A. Dubrawski, "Neural basis expansion analysis with exogenous variables: Forecasting electricity prices with NBEATSx," *Int. J. Forecasting*, vol. 39, pp. 884–900, 2023.
[92] I. O. Tolstikhin et al., "MLP-mixer: An all-MLP architecture for vision," in *Proc. Int. Conf. Neural Inf. Process. Syst.*, 2021, pp. 24261–24272.
[93] S.-A. Chen, C.-L. Li, N. Yoder, S. O. Arik, and T. Pfister, "TSMixer: An all-MLP architecture for time series forecasting," *Trans. Mach. Learn. Res.*, pp. 2835–8856, 2023.
[94] A. Das, W. Kong, A. Leach, R. Sen, and R. Yu, "Long-term forecasting with tide: Time-series dense encoder," *Trans. Mach. Learn. Res.*, pp. 2835–8856, 2023.
[95] P. J. Schmid, "Dynamic mode decomposition of numerical and experimental data," *J. Fluid Mechanics*, vol. 656, pp. 5–28, 2010.
[96] Y. Liu, C. Li, J. Wang, and M. Long, "Koopa: Learning non-stationary time series dynamics with Koopman predictors," in *Proc. Int. Conf. Neural Inf. Process. Syst.*, 2023, Art. no. 538.
[97] S. Hochreiter and J. Schmidhuber, "Long short-term memory," *Neural Computation*, vol. 9, pp. 1735–1780, 1997.
[98] I. Sutskever, O. Vinyals, and Q. V. Le, "Sequence to sequence learning with neural networks," in *Proc. Int. Conf. Neural Inf. Process. Syst.*, 2014, pp. 3104–3112.
[99] K. Cho et al., "Learning phrase representations using RNN encoder–decoder for statistical machine translation," in *Proc. Conf. Empirical Methods Natural Lang. Process.*, 2014, pp. 1724–1734.
[100] R. Nallapati, B. Zhou, C. Gulcehre, and B. Xiang, "Abstractive text summarization using sequence-to-sequence RNNs and beyond," in *Proc. 20th SIGNLL Conf. Comput. Natural Lang. Learn.*, 2016, pp. 280–290.

Authorized licensed use limited to: XIDIAN UNIVERSITY. Downloaded on October 13,2026 at 08:55:48 UTC from IEEE Xplore. Restrictions apply.

[101] S. Mehri et al., "SampleRNN: An unconditional end-to-end neural audio generation model," in *Proc. Int. Conf. Learn. Representations*, 2017, pp. 1696–1706.
[102] A. Tealab, "Time series forecasting using artificial neural networks methodologies: A systematic review," *Future Comput. Informat. J.*, vol. 3, pp. 334–340, 2018.
[103] W. Cao, D. Wang, J. Li, H. Zhou, L. Li, and Y. Li, "BRITS: Bidirectional recurrent imputation for time series," in *Proc. Int. Conf. Neural Inf. Process. Syst.*, 2018, pp. 6776–6786.
[104] J. Yoon, W. R. Zame, and M. van der Schaar, "Estimating missing data in temporal data streams using multi-directional recurrent neural networks," *IEEE Trans. Biomed. Eng.*, vol. 66, no. 5, pp. 1477–1490, May 2019.
[105] Z. Che, S. Purushotham, K. Cho, D. Sontag, and Y. Liu, "Recurrent neural networks for multivariate time series with missing values," *Sci. Rep.*, vol. 8, 2018, Art. no. 6085.
[106] I. M. Baytas, C. Xiao, X. Zhang, F. Wang, A. K. Jain, and J. Zhou, "Patient subtyping via time-aware LSTM networks," in *Proc. ACM SIGKDD Int. Conf. Knowl. Discov. Data Mining*, 2017, pp. 65–74.
[107] L. Shen, Z. Li, and J. Kwok, "Timeseries anomaly detection using temporal hierarchical one-class network," in *Proc. Int. Conf. Neural Inf. Process. Syst.*, 2020, Art. no. 1092.
[108] G. Lai, W.-C. Chang, Y. Yang, and H. Liu, "Modeling long-and short-term temporal patterns with deep neural networks," in *Proc. 41st Int. ACM SIGIR Conf. Res. Develop. Inf. Retrieval*, 2018, pp. 95–104.
[109] Y. Qin, D. Song, H. Chen, W. Cheng, G. Jiang, and G. Cottrell, "A dual-stage attention-based recurrent neural network for time series prediction," in *Proc. Int. Joint Conf. Artif. Intell.*, 2017, pp. 2627–2633.
[110] D. Salinas, V. Flunkert, J. Gasthaus, and T. Januschowski, "DeepAR: Probabilistic forecasting with autoregressive recurrent networks," *Int. J. Forecasting*, vol. 36, pp. 1181–1191, 2020.
[111] A. Gu et al., "Combining recurrent, convolutional, and continuous-time models with linear state space layers," in *Proc. Int. Conf. Neural Inf. Process. Syst.*, 2021, Art. no. 44.
[112] M. Fraccaro, S. K. Sønderby, U. Paquet, and O. Winther, "Sequential neural models with stochastic layers," in *Proc. Int. Conf. Neural Inf. Process. Syst.*, 2016, pp. 2207–2215.
[113] R. Krishnan, U. Shalit, and D. Sontag, "Structured inference networks for nonlinear state space models," in *Proc. AAAI Conf. Artif. Intell.*, 2017, pp. 2101–2109.
[114] S. S. Rangapuram, M. W. Seeger, J. Gasthaus, L. Stella, Y. Wang, and T. Januschowski, "Deep state space models for time series forecasting," in *Proc. Int. Conf. Neural Inf. Process. Syst.*, 2018, pp. 7796–7805.
[115] A. Gu, K. Goel, and C. Ré, "Efficiently modeling long sequences with structured state spaces," in *Proc. Int. Conf. Learn. Representations*, 2022, pp. 14323–14349.
[116] A. Gu and T. Dao, "Mamba: Linear-time sequence modeling with selective state spaces," 2024, *arXiv:2312.00752*.
[117] R. T. Chen, Y. Rubanova, J. Bettencourt, and D. K. Duvenaud, "Neural ordinary differential equations," in *Proc. Int. Conf. Neural Inf. Process. Syst.*, 2018, pp. 6572–6583.
[118] Y. Rubanova, R. T. Chen, and D. K. Duvenaud, "Latent ordinary differential equations for irregularly-sampled time series," in *Proc. Int. Conf. Neural Inf. Process. Syst.*, 2019, pp. 5321–5331.
[119] P. Kidger, J. Morrill, J. Foster, and T. Lyons, "Neural controlled differential equations for irregular time series," in *Proc. Int. Conf. Neural Inf. Process. Syst.*, 2020, Art. no. 562.
[120] Y. Yin et al., "Augmenting physical models with deep networks for complex dynamics forecasting," *J. Stat. Mechanics Theory Experiment*, vol. 2021, 2021, Art. no. 124012.
[121] J. Gu et al., "Recent advances in convolutional neural networks," *Pattern Recognit.*, vol. 77, pp. 354–377, 2018.
[122] M. Tan and Q. Le, "EfficientNet: Rethinking model scaling for convolutional neural networks," in *Proc. Int. Conf. Mach. Learn.*, 2019, pp. 6105–6114.
[123] S. Minaee, Y. Boykov, F. Porikli, A. Plaza, N. Kehtarnavaz, and D. Terzopoulos, "Image segmentation using deep learning: A survey," *IEEE Trans. Pattern Anal. Mach. Intell.*, vol. 44, no. 7, pp. 3523–3542, Jul. 2022.
[124] J. Redmon, S. Divvala, R. Girshick, and A. Farhadi, "You only look once: Unified, real-time object detection," in *Proc. IEEE Conf. Comput. Vis. Pattern Recognit.*, 2016, pp. 779–788.
[125] A. Le Guennec, S. Malinowski, and R. Tavenard, "Data augmentation for time series classification using convolutional neural networks," in *Proc. ECML/PKDD Workshop Adv. Analytics Learn. Temporal Data*, 2016, p. 11.
[126] H. Ismail Fawaz et al., "InceptionTime: Finding alexnet for time series classification," *Data Mining Knowl. Discov.*, vol. 34, pp. 1936–1962, 2020.
[127] M. Liu et al., "SCINet: Time series modeling and forecasting with sample convolution and interaction," in *Proc. Int. Conf. Neural Inf. Process. Syst.*, 2022, Art. no. 421.
[128] A. v. d. Oord et al., "WaveNet: A generative model for raw audio," in *Proc. 9th ISCA Speech Synth. Workshop*, 2016, Art. no. 125.
[129] S. Bai, J. Z. Kolter, and V. Koltun, "An empirical evaluation of generic convolutional and recurrent networks for sequence modeling," 2018, *arXiv:1803.01271*.
[130] H. Wang, J. Peng, F. Huang, J. Wang, J. Chen, and Y. Xiao, "MICN: Multi-scale local and global context modeling for long-term series forecasting," in *Proc. Int. Conf. Learn. Representations*, 2023, pp. 13014–13035.
[131] D. Luo and X. Wang, "ModernTCN: A modern pure convolution structure for general time series analysis," in *Proc. Int. Conf. Learn. Representations*, 2024, pp. 34209–34251.
[132] C. Szegedy et al., "Going deeper with convolutions," in *Proc. IEEE Conf. Comput. Vis. Pattern Recognit.*, 2015, pp. 1–9.
[133] C. Szegedy, V. Vanhoucke, S. Ioffe, J. Shlens, and Z. Wojna, "Rethinking the inception architecture for computer vision," in *Proc. IEEE Conf. Comput. Vis. Pattern Recognit.*, 2016, pp. 2818–2826.
[134] F. Scarselli, M. Gori, A. C. Tsoi, M. Hagenbuchner, and G. Monfardini, "The graph neural network model," *IEEE Trans. Neural Netw. Learn. Syst.*, vol. 20, no. 1, pp. 61–80, Jan. 2009.
[135] T. N. Kipf and M. Welling, "Semi-supervised classification with graph convolutional networks," in *Proc. Int. Conf. Learn. Representations*, 2017, pp. 2713–2726.
[136] Y. Li, R. Yu, C. Shahabi, and Y. Liu, "Diffusion convolutional recurrent neural network: Data-driven traffic forecasting," in *Proc. Int. Conf. Learn. Representations*, 2018, pp. 2079–2094.
[137] B. Yu, H. Yin, and Z. Zhu, "Spatio-temporal graph convolutional networks: A deep learning framework for traffic forecasting," in *Proc. Int. Joint Conf. Artif. Intell.*, 2018, pp. 3634–3640.
[138] Z. Wu, S. Pan, G. Long, J. Jiang, and C. Zhang, "Graph wavenet for deep spatial-temporal graph modeling," in *Proc. Int. Joint Conf. Artif. Intell.*, 2019, pp. 1907–1913.
[139] L. Bai, L. Yao, C. Li, X. Wang, and C. Wang, "Adaptive graph convolutional recurrent network for traffic forecasting," in *Proc. Int. Conf. Neural Inf. Process. Syst.*, 2020, Art. no. 1494.
[140] Z. Wu, S. Pan, G. Long, J. Jiang, X. Chang, and C. Zhang, "Connecting the dots: Multivariate time series forecasting with graph neural networks," in *Proc. ACM SIGKDD Int. Conf. Knowl. Discov. Data Mining*, 2020, pp. 753–763.
[141] M. Li and Z. Zhu, "Spatial-temporal fusion graph neural networks for traffic flow forecasting," in *Proc. AAAI Conf. Artif. Intell.*, 2021, pp. 4189–4196.
[142] J. Lu, D. Batra, D. Parikh, and S. Lee, "ViLBERT: Pretraining task-agnostic visiolinguistic representations for vision-and-language tasks," in *Proc. Int. Conf. Neural Inf. Process. Syst.*, 2019, Art. no. 2.
[143] Z. Yang, Z. Dai, Y. Yang, J. Carbonell, R. R. Salakhutdinov, and Q. V. Le, "XLNet: Generalized autoregressive pretraining for language understanding," in *Proc. Int. Conf. Neural Inf. Process. Syst.*, 2019, Art. no. 517.
[144] T. Brown et al., "Language models are few-shot learners," in *Proc. Int. Conf. Neural Inf. Process. Syst.*, 2020, Art. no. 159.
[145] W. X. Zhao et al., "A survey of large language models," 2023, *arXiv:2303.18223*.
[146] H. Touvron, M. Cord, M. Douze, F. Massa, A. Sablayrolles, and H. Jégou, "Training data-efficient image transformers & distillation through attention," in *Proc. Int. Conf. Mach. Learn.*, 2021, pp. 10347–10357.
[147] Z. Liu et al., "Swin transformer: Hierarchical vision transformer using shifted windows," in *Proc. IEEE Int. Conf. Comput. Vis.*, 2021, pp. 9992–10002.
[148] W. Wang et al., "Pyramid vision transformer: A versatile backbone for dense prediction without convolutions," in *Proc. IEEE Int. Conf. Comput. Vis.*, 2021, pp. 548–558.
[149] A. Vaswani et al., "Attention is all you need," in *Proc. Int. Conf. Neural Inf. Process. Syst.*, 2017, pp. 5998–6008.
[150] S. Li et al., "Enhancing the locality and breaking the memory bottleneck of transformer on time series forecasting," in *Proc. Int. Conf. Neural Inf. Process. Syst.*, 2019, pp. 5244–5254.
[151] S. Liu et al., "PyraFormer: Low-complexity pyramidal attention for long-range time series modeling and forecasting," in *Proc. Int. Conf. Learn. Representations*, 2022, pp. 18639–18658.

Authorized licensed use limited to: XIDIAN UNIVERSITY. Downloaded on October 13,2026 at 08:55:48 UTC from IEEE Xplore. Restrictions apply.

[152] Y. Zhang and J. Yan, "Crossformer: Transformer utilizing cross-dimension dependency for multivariate time series forecasting," in *Proc. Int. Conf. Learn. Representations*, 2023, pp. 5268–5289.
[153] T. Zhou et al., "One fits all: Power general time series analysis by pretrained LM," in *Proc. Int. Conf. Neural Inf. Process. Syst.*, 2024, Art. no. 1877.
[154] Y. Liu, H. Zhang, C. Li, X. Huang, J. Wang, and M. Long, "Timer: Transformers for time series analysis at scale," in *Proc. Int. Conf. Mach. Learn.*, 2024, Art. no. 1313.
[155] S. Papoulis, *Probability, Random Variables and Stochastic Processes by Athanasios*. Boston, MA, USA: McGraw-Hill, 2002.
[156] W. Xue, T. Zhou, Q. Wen, J. Gao, B. Ding, and R. Jin, "CARD: Channel aligned robust blend transformer for time series forecasting," in *Proc. Int. Conf. Learn. Representations*, 2024, pp. 20577–20615.
[157] P. Chen et al., "Multi-scale transformers with adaptive pathways for time series forecasting," in *Proc. Int. Conf. Learn. Representations*, 2024, pp. 13193–13211.
[158] Y. Wang et al., "TimeXer: Empowering transformers for time series forecasting with exogenous variables," in *Proc. Int. Conf. Neural Inf. Process. Syst.*, 2024, Art. no. 15.
[159] S. Dooley, G. S. Khurana, C. Mohapatra, S. V. Naidu, and C. White, "ForecastPFN: Synthetically-trained zero-shot forecasting," in *Proc. Int. Conf. Neural Inf. Process. Syst.*, 2023, Art. no. 112.
[160] M. Goswami, K. Szafer, A. Choudhry, Y. Cai, S. Li, and A. Dubrawski, "MOMENT: A family of open time-series foundation models," in *Proc. Int. Conf. Mach. Learn.*, 2024, Art. no. 642.
[161] G. Woo, C. Liu, A. Kumar, C. Xiong, S. Savarese, and D. Sahoo, "Unified training of universal time series forecasting transformers," in *Proc. Int. Conf. Mach. Learn.*, 2024, Art. no. 2178.
[162] X. Liu et al., "Moirai-MoE: Empowering time series foundation models with sparse mixture of experts," in *Proc. Int. Conf. Mach. Learn.*, 2025, pp. 38940–38962.
[163] V. Ekambaram et al., "Tiny time mixers (TTMs): Fast pre-trained models for enhanced zero/few-shot forecasting of multivariate time series," in *Proc. Int. Conf. Neural Inf. Process. Syst.*, 2024, Art. no. 2359.
[164] A. Auer, P. Podest, D. Klotz, S. Böck, G. Klambauer, and S. Hochreiter, "TiRex: Zero-shot forecasting across long and short horizons with enhanced in-context learning," in *Proc. Int. Conf. Neural Inf. Process. Syst.*, 2025, pp. 57529–57580.
[165] K. Rasul et al., "Lag-Llama: Towards foundation models for time series forecasting," 2023, *arXiv:2310.08278*.
[166] A. Das, W. Kong, R. Sen, and Y. Zhou, "A decoder-only foundation model for time-series forecasting," in *Proc. Int. Conf. Mach. Learn.*, 2024, Art. no. 404.
[167] X. Shi et al., "Time-MoE: Billion-scale time series foundation models with mixture of experts," in *Proc. Int. Conf. Learn. Representations*, 2025, pp. 30785–30817.
[168] Y. Liu et al., "Sundial: A family of highly capable time series foundation models," in *Proc. Int. Conf. Mach. Learn.*, 2025, Art. no. 1572.
[169] B. Cohen et al., "Toto: Time series optimized transformer for observability," 2024, *arXiv:2407.07874*.
[170] S. Q. N. Gruver, M. Finzi, and A. G. Wilson, "Large language models are zero shot time series forecasters," in *Proc. Int. Conf. Neural Inf. Process. Syst.*, 2023, Art. no. 861.
[171] A. F. Ansari et al., "Chronos: Learning the language of time series," *Trans. Mach. Learn. Res.*, 2024, pp. 2835–8856.
[172] A. F. Ansari et al., "Chronos-2: From univariate to universal forecasting," 2025, *arXiv:2510.15821*.
[173] F. Li et al., "Dynamic graph convolutional recurrent network for traffic prediction: Benchmark and solution," *ACM Trans. Knowl. Discov. Data*, vol. 17, 2023, Art. no. 9.
[174] J. Wang, J. Jiang, W. Jiang, C. Li, and W. X. Zhao, "LibCity: An open library for traffic prediction," in *Proc. 29th Int. Conf. Adv. Geographic Inf. Syst.*, 2021, pp. 145–148.
[175] R. Jiang et al., "DL-Traff: Survey and benchmark of deep learning models for urban traffic prediction," in *Proc. 30th ACM Int. Conf. Inf. Knowl. Manage.*, 2021, pp. 4515–4525.
[176] Y. Hao et al., "TS-Benchmark: A benchmark for time series databases," in *Proc. IEEE Int. Conf. Data Eng.*, 2021, pp. 588–599.
[177] R. Tavenard et al., "Tslearn, a machine learning toolkit for time series data," *J. Mach. Learn. Res.*, vol. 21, 2020, Art. no. 118.
[178] F. Garza, M. M. Canseco, C. Challú, and K. G. Olivares, "StatsForecast: Lightning fast forecasting with statistical and econometric models," 2022. [Online]. Available: https://github.com/Nixtla/statsforecast
[179] K. G. Olivares, C. Challú, A. Garza, M. M. Canseco, and A. Dubrawski, "NeuralForecast: User friendly state-of-the-art neural forecasting models," 2022. [Online]. Available: https://github.com/Nixtla/neuralforecast
[180] A. Alexandrov et al., "GluonTS: Probabilistic and neural time series modeling in Python," *J. Mach. Learn. Res.*, vol. 21, 2020, Art. no. 116.
[181] S. Makridakis, E. Spiliotis, and V. Assimakopoulos, "The M4 competition: 100,000 time series and 61 forecasting methods," *Int. J. Forecasting*, vol. 36, pp. 54–74, 2020.
[182] Y. Su, Y. Zhao, C. Niu, R. Liu, W. Sun, and D. Pei, "Robust anomaly detection for multivariate time series through stochastic recurrent neural network," in *Proc. ACM SIGKDD Int. Conf. Knowl. Discov. Data Mining*, 2019, pp. 2828–2837.
[183] K. Hundman, V. Constantinou, C. Laporte, I. Colwell, and T. Soderstrom, "Detecting spacecraft anomalies using LSTMs and nonparametric dynamic thresholding," in *Proc. ACM SIGKDD Int. Conf. Knowl. Discov. Data Mining*, 2018, pp. 387–395.
[184] A. P. Mathur and N. O. Tippenhauer, "SWaT: A water treatment testbed for research and training on ICS security," in *Proc. Int. Workshop Cyber-Phys. Syst. Smart Water Netw.*, 2016, pp. 31–36.
[185] A. Abdulaal, Z. Liu, and T. Lancewicki, "Practical approach to asynchronous multivariate time series anomaly detection and localization," in *Proc. ACM SIGKDD Int. Conf. Knowl. Discov. Data Mining*, 2021, pp. 2485–2494.
[186] A. J. Bagnall et al., "The UEA multivariate time series classification archive, 2018,," 2018, *arXiv:1811.00075*.
[187] G. Zerveas, S. Jayaraman, D. Patel, A. Bhamidipaty, and C. Eickhoff, "A transformer-based framework for multivariate time series representation learning," in *Proc. ACM SIGKDD Int. Conf. Knowl. Discov. Data Mining*, 2021, pp. 2114–2124.
[188] S. Wang et al., "TimeMixer: Decomposable multiscale mixing for time series forecasting," in *Proc. Int. Conf. Learn. Representations*, 2024, pp. 4166–4192.
[189] W. Cai, Y. Liang, X. Liu, J. Feng, and Y. Wu, "MSGNet: Learning multi-scale inter-series correlations for multivariate time series forecasting," in *Proc. AAAI Conf. Artif. Intell.*, 2024, Art. no. 1243.
[190] Y. Hu et al., "TimeFilter: Patch-specific spatial-temporal graph filtration for time series forecasting," in *Proc. Int. Conf. Mach. Learn.*, 2025, Art. no. 975.
[191] X. Qiu, T. Sun, Y. Xu, Y. Shao, N. Dai, and X. Huang, "Pre-trained models for natural language processing: A survey," *Sci. China Technol. Sci.*, vol. 63, pp. 1872–1897, 2020.
[192] K. He, H. Fan, Y. Wu, S. Xie, and R. Girshick, "Momentum contrast for unsupervised visual representation learning," in *Proc. IEEE Conf. Comput. Vis. Pattern Recognit.*, 2020, pp. 9726–9735.
[193] X. Liu et al., "Self-supervised learning: Generative or contrastive," *IEEE Trans. Knowl. Data Eng.*, vol. 35, no. 1, pp. 857–876, Jan. 2023.
[194] A. Jaiswal, A. R. Babu, M. Z. Zadeh, D. Banerjee, and F. Makedon, "A survey on contrastive self-supervised learning," *Technologies*, vol. 9, 2020, Art. no. 2.
[195] K. He, X. Chen, S. Xie, Y. Li, P. Dollár, and R. Girshick, "Masked autoencoders are scalable vision learners," in *Proc. IEEE Conf. Comput. Vis. Pattern Recognit.*, 2022, pp. 15979–15988.
[196] T. Chen, S. Kornblith, M. Norouzi, and G. Hinton, "A simple framework for contrastive learning of visual representations," in *Proc. Int. Conf. Mach. Learn.*, 2020, Art. no. 149.
[197] A. v. d. Oord, Y. Li, and O. Vinyals, "Representation learning with contrastive predictive coding," 2018, *arXiv:1807.03748*.
[198] Z. Yue et al., "TS2Vec: Towards universal representation of time series," in *Proc. AAAI Conf. Artif. Intell.*, 2022, pp. 8980–8987.
[199] E. Eldele et al., "Time-series representation learning via temporal and contextual contrasting," in *Proc. Int. Joint Conf. Artif. Intell.*, 2021, pp. 2352–2359.
[200] G. Woo, C. Liu, D. Sahoo, A. Kumar, and S. Hoi, "CoST: Contrastive learning of disentangled seasonal-trend representations for time series forecasting," in *Proc. Int. Conf. Learn. Representations*, 2022, pp. 9883–9900.
[201] A. Baevski, W.-N. Hsu, Q. Xu, A. Babu, J. Gu, and M. Auli, "Data2vec: A general framework for self-supervised learning in speech, vision and language," in *Proc. Int. Conf. Mach. Learn.*, 2022, pp. 1298–1312.
[202] G. Zerveas, S. Jayaraman, D. Patel, A. Bhamidipaty, and C. Eickhoff, "A transformer-based framework for multivariate time series representation learning," in *Proc. ACM SIGKDD Int. Conf. Knowl. Discov. Data Mining*, 2021, pp. 2114–2124.

Authorized licensed use limited to: XIDIAN UNIVERSITY. Downloaded on October 13,2026 at 08:55:48 UTC from IEEE Xplore. Restrictions apply.

[203] S. Zhao et al., "HiMTM: Hierarchical multi-scale masked time series modeling for long-term forecasting," in *Proc. 33rd ACM Int. Conf. Inf. Knowl. Manage.*, 2024, pp. 3352–3362.
[204] J. Dong, H. Wu, H. Zhang, L. Zhang, J. Wang, and M. Long, "SimMTM: A simple pre-training framework for masked time-series modeling," in *Proc. Int. Conf. Neural Inf. Process. Syst.*, 2023, Art. no. 1306.
[205] J. Dong et al., "TimeSiam: A pre-training framework for Siamese time-series modeling," in *Proc. Int. Conf. Mach. Learn.*, 2024, Art. no. 453.



王宇轩于2022年获得北京航空航天大学学士学位。目前在清华大学攻读计算机软件方向博士学位。她的研究兴趣包括机器学习和时间序列分析。



吴海旭于2020年获得清华大学软件工程学士学位。目前在清华大学攻读计算机软件方向博士学位。他的研究兴趣包括科学机器学习、深度学习和时空学习。



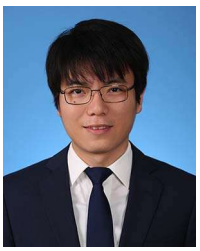
董家祥于2018年获得南开大学计算机科学与技术硕士学位。目前在清华大学攻读计算机软件方向博士学位。他的研究兴趣包括机器学习和时间序列分析。



刘永于2021年获得清华大学软件工程学士学位。目前在清华大学攻读计算机软件方向博士学位。他的研究兴趣包括时间序列分析和时间序列基础模型。



陈旺于2003年和2006年分别获得复旦大学计算机科学学士和硕士学位。目前是清华大学大数据软件国家工程实验室的研究副教授兼首席技术官。他的研究方向包括数据库系统、数据治理、时间序列数据管理以及工业大数据应用。



龙明胜于2008年和2014年分别获得清华大学学士和博士学位。他是清华大学软件学院的终身副教授。他担任《IEEE模式分析与机器智能汇刊》和《人工智能期刊》的副编辑，并担任NeurIPS、ICML和ICLR等主要机器学习会议的高级/重点领域主席。他的研究致力于机器学习理论、算法和模型，尤其关注深度学习以及基础模型、科学学习与世界模型、迁移学习和领域自适应。



王建民于1990年获得北京大学学士学位，1992年和1995年分别获得清华大学计算机软件硕士和博士学位。他是清华大学软件学院的全职教授。他的研究兴趣包括大数据管理系统和大规模数据分析。他牵头开发了产品数据与生命周期管理系统，该系统已在中国数百家企业中部署。他目前正牵头开发清华大学DataWay大数据平台和Apache IoTDB时序数据库系统，依托大数据软件国家工程实验室开展。

Authorized licensed use limited to: XIDIAN UNIVERSITY. Downloaded on October 13,2026 at 08:55:48 UTC from IEEE Xplore. Restrictions apply.